

Détection automatique de fissures dans des images de chaussée par modélisation markovienne

Hanan SALAM

Résumé : Ce travail présente une méthode de détection automatique de fissures dans des images de chaussées en s'appuyant sur une segmentation par modélisation markovienne.

Mots-clés : Traitement d'images, détection, segmentation, Markov, fissures, chaussée.

Encadrants

Jérôme IDIER, chercheur au CNRS

Sylvie CHAMBON, chercheuse au LCPC

Institut de Recherche en Communications et Cybernétique de Nantes, IRCCyN

UMR CNRS 6597

École central de Nantes, 1 rue de la Noë - 44321 Nantes

Laboratoire Central des Ponts et Chaussées, LCPC, Nantes
route de Pornic, BP 4129, 44341 Bouguenais

Septembre 2010

Table des matières

Table des matières	iii
Table des figures	iv
Liste des tableaux	v
Remerciements	1
Introduction	3
1. Détection semi-automatique des fissures	7
1.1. Types des fissures	7
1.2. Phases de système de détection des fissures	8
1.2.1. Acquisition des données	9
1.2.2. Stockage des données	9
1.2.3. Traitement des données	9
1.3. Méthodes actuelles	11
1.3.1. Méthodes par apprentissage	12
1.3.2. Méthodes globales	12
1.3.3. Méthodes comparées	13
2. Segmentation par modélisation markovienne	17
2.1. Sites, cliques et voisinages dans une image	17
2.2. Notions d'énergies locale et globale	18
2.3. Définition d'un champ de Markov	19
2.4. Théorème de Hammersley-Clifford	19
2.5. Segmentation dans le cadre bayésien	21
3. Application aux images de chaussées	25
3.1. Modèle	27
3.1.1. Chien-modèle	27
3.1.2. Terme d'attache aux données	30

3.1.3. Estimation des paramètres	31
3.1.4. Méthode d'optimisation utilisée	33
3.2. Algorithme	35
4. Expérimentation	37
4.1. Protocole d'évaluation	37
4.1.1. Images de test	37
4.1.2. Segmentation de référence	39
4.1.3. Critères d'évaluation	40
4.2. Résultats expérimentaux	41
4.2.1. Pré-traitements	43
4.2.2. Influence des paramètres	44
4.2.3. Images de résultats	46
4.2.4. Influence de la méthode d'estimation	56
4.2.5. Comparaison aux méthodes proposées au LCPC	56
Conclusion et perspectives	61
A. Systèmes d'acquisition	65
B. Champs de Markov : modèle fondamental et échantillonage	67
B.1. Modèle d'Ising	67
B.2. Échantillonage des champs de Markov	68
B.2.1. Échantillonneur de Gibbs	68
B.2.2. Algorithme de Metropolis	68

Table des figures

1.1.	Exemple d'images de chaussées présentant des fissures.	8
1.2.	Image de la chaussée avec un éclairage non uniforme.	10
1.3.	Quelques exemples d'images avec leurs histogrammes.	12
1.4.	Images de résultats par la méthode à base de morphologie mathématique.	14
1.5.	Résultats de segmentation obtenus avec la méthode [Chambon 09].	15
2.1.	Cliques associées à deux systèmes de voisinage en dimension 2.	18
3.1.	Équations associées aux contours pour le chien-modèle.	29
3.2.	Équations associées aux lignes pour le chien-modèle.	30
3.4.	Algorithme itératif EM pour l'estimation des paramètres du chien-modèle.	33
3.5.	Algorithme d'estimation d'un champ de Markov.	34
3.6.	Algorithme de segmentation des images de chaussées.	35
3.3.	Configurations binaires et leurs potentiels dans le chien-modèle.	36
4.1.	Catégories d'images de test utilisées.	38
4.2.	Images acquises en statique.	38
4.3.	Images acquises en dynamique.	38
4.4.	Images de test avec les segmentations de référence.	39
4.5.	Schéma présentant les critères d'évaluation.	40
4.6.	Images de synthèse et segmentations obtenues en connaissant les paramètres.	42
4.7.	Comparaison des résultats de segmentation avec et sans prétraitement.	43
4.8.	Taux de faux positifs en fonction du taux des vrais positifs.	45
4.9.	Variation de la valeur du DICE en fonction des différents jeux de paramètres.	46
4.10.	Détails d'un résultat sur une image réelle.	52
4.11.	Comparaison des résultats entre le chien-modèle et les autres méthodes.	57
4.12.	Segmentations de référence utilisées dans le protocole d'évaluation.	63
B.1.	Échantillonneur de Gibbs.	68

B.2. Algorithme de Metropolis.	69
--	----

Liste des tableaux

3.1. Classification des méthodes de détection des objets fins.	27
4.1. Critères d'évaluation d'une segmentation automatique	41
4.2. Valeurs utilisées pour segmenter les images de synthèse.	42
4.3. Images des résultats des images acquises en statique.	52
4.4. Images des résultats des images acquises en dynamique.	55
4.5. Comparaison des résultats du chien-modèle avec les méthodes LCPC.	60

Remerciements

Je tiens à remercier sincèrement, mes encadrants : Sylvie Chambon au LCPC, et Jérôme Idier de l'IRCCyN pour leur aide et les conseils concernant les missions évoquées dans ce rapport, qu'ils m'ont apporté lors des différentes réunion de suivi. Ils m'ont aidé à devenir plus systématique dans mon travail et à mieux comprendre la philosophie de la recherche.

Merci aux membres de l'équipe "Auscultation et Imagerie" Philippe NICOLLE et Jean-Marc MOLIARD d'avoir répondu à toutes mes questions et de leur aide pour avancer pendant mon stage au LCPC.

Je remercie aussi toute l'équipe pédagogique de l'école centrale de Nantes et les intervenants professionnels responsables de la formation "Traitement du signal et image", pour avoir assuré la partie théorique de celle-ci.

Je tiens à remercier tout particulièrement le doyen de la faculté de génie de l'université Libanaise Pr. Mohammad Zoaiter pour ouvrir la porte aux universités de France.

Mes remerciements s'adressent également à ma famille et mes amis qui m'ont accompagnée et soutenue sans relâche durant toutes ces années d'études.

Enfin, je remercie tous mes professeurs à l'université libanaise et les membres du jury.

Introduction

Le processus de segmentation est une étape importante dans l'analyse d'images, c'est un traitement de bas niveau qui consiste à extraire une partition de l'image en sous-ensembles connexes de points de l'image (pixels) ayant des propriétés communes (intensité lumineuse, texture, couleur...) qui les différencient des pixels des régions voisines [Maredj 02]. Il existe plusieurs méthodes de segmentation, chacune diffère l'une de l'autre par le principe utilisé et le but visé. Ainsi, il est important d'adapter la méthode de segmentation à la problématique traitée en prenant en considération toutes les spécifications de l'image analysée.

La problématique traitée dans ce rapport est celle de la segmentation des fissures dans des images de chaussées. Par définition, une fissure est une ligne de rupture apparaissant à la surface de la chaussée [LCPC 98]. Dans le contexte du traitement d'images, une fissure est définie comme un ensemble des pixels qui sont plus sombres que le fond. Une autre définition est souvent utilisée [Delagnes 95, Chambon 09, Subirats 06] : la fissure est un ensemble de petits segments connectés qui possèdent éventuellement des orientations différentes.

Principalement, l'existence de fissures à la surface des chaussées est due aux conditions climatiques et au trafic de poids lourds [LCPC 98]. Ce type de dégradations constituent un des indicateurs de l'état de santé et de l'évolution de la structure des chaussées. Une détection efficace des fissures va permettre d'évaluer l'état des chaussées et de programmer les opérations de maintenance. Le travail de détection des fissures est réalisé visuellement par des agents spécialisés. La première étape de leur travail consiste à acquérir une vidéo de la surface de la chaussée en circulant avec un véhicule à faible vitesse. La deuxième étape concerne la saisie des informations sur les dégradations sur un poste dédié. C'est un travail fastidieux qui met en péril la sécurité des agents et les usagers de la route et qui donne des résultats qui ne sont pas entièrement fiables (car il est dépendant de l'agent). De plus, on a un problème de reproductibilité dû à la variabilité des conditions d'observation naturelles (pluie, orages...). En raison de ces limitations, certaines recherches ont été dirigées vers l'automatisation de ce travail pour aider les agents à relever les défauts au bureau. Cette tran-

sition nécessite la mise en œuvre de méthodes de traitement automatique des images de la route.

Cette tâche d'automatisation est une tâche très difficile car c'est un problème d'extraction d'objets fins sur un fond texturé très bruité. La difficulté à distinguer les fissures vient du fait que la granularité de la texture dans l'image de chaussée peut correspondre à la largeur des fissures et les intensités de certains pixels de la fissure correspondent aux intensités présentes à la surface de la chaussée. De plus, le revêtement de la surface de la chaussée, l'éclairage non constant, les objets qui peuvent être présents et les marquages routiers rendent cette tâche plus délicate.

Actuellement, dans ce contexte plusieurs méthodes de segmentation ont été développées. Ces méthodes ont donné des résultats à peu près fiables mais ils présentent des limites : la présence de fausses detections et une segmentation incomplète du défaut. Plus précisément, au sein du LCPC (Laboratoire Central des Ponts et Chaussées), deux méthodes de détection de fissures ont été explorées : une méthode basée sur des outils de morphologie mathématique, et une par filtrage adapté combinée avec une segmentation par modélisation markovienne [Chambon 08]. La modélisation markovienne est un traitement probabiliste de l'image. Depuis quelques années, elle a été largement utilisée en segmentation dans différents domaines en raison de la nature stochastique des problèmes (modélisation des textures et des déformations observées sur les images).

D'après le travail de [Subirats 06] poursuivi par [Chambon 08], nous avons pu constater l'intérêt de la modélisation markovienne pour la segmentation des fissures : capacité de prendre en compte les aspects géométriques des fissures (orientation locale fixe de la fissure). Cet intérêt et les limites des différentes méthodes de détection dans la littérature ont donné lieu à l'objectif principal de ce stage de recherche de master : la proposition et l'application d'une méthode de segmentation pour la détection des fissures basée sur une nouvelle modélisation markovienne et la comparaison des résultats de cette méthode avec les résultats obtenus par les méthodes étudiées au LCPC.

Dans la suite de ce mémoire, premièrement, nous présentons l'état de l'art sur la détection des fissures qui comprend les étapes de base d'automatisation de la détection des fissures et un résumé des méthodes de détection dans la littérature. Deuxièmement, nous donnons une description de la modélisation markovienne en traitement d'images et l'application de cette modélisation à la segmentation d'images. Finalement, nous proposons d'étudier une méthode de détection semi-automatique de détection de fissure basée sur la modélisation markovienne, en présentant le modèle markovien adopté et les résultats expérimentaux obtenus par cette

méthode. Finalement, nous analysons les points forts de cette méthode et ses limites.

Chapitre 1

Détection semi-automatique des fissures

Premièrement, nous définissons les types des fissures auxquels nous nous intéressons.

1.1 Types des fissures

Plusieurs types des fissures sont possibles sur la route, quelques exemples sont donnés ici et illustrés par les images présentées dans la figure 1.1.

- **Fissure transversale** – Les fissures transversales sont perpendiculaires à l'axe de circulation de la chaussée. Elles peuvent être isolées ou espacées périodiquement (espacement variable).
- **Fissure longitudinale** – Les fissures longitudinales sont parallèles à l'axe de circulation de la chaussée. On peut distinguer celles qui apparaissent exclusivement dans une bande de roulement de celles qui sont non spécifiques aux bandes de roulement.
- **Fissure oblique** – Les fissures obliques correspondent aux cassures de dalle rejoignant deux côtés adjacents et elles sont situées à plus de 50 cm du coin de la dalle.
- **Le faïençage** est un ensemble des fissures entrelacées ou maillées formant une série de polygones. On distingue le faïençage dans les bandes de roulement, le faïençage non spécifique aux bandes de roulement et le faïençage circulaire.
- **Les fissures diverses** sont des fissures apparaissant d'une façon anarchique à la surface des chaussées. On rencontre des fissures paraboliques, en étoile ou en Y.

Nous mentionnons également les fissures de joint, les fissures d'adaptation, les fissures fines de surface... etc. Pour avoir plus de détails le lecteur peut consulter [LCPC 98].

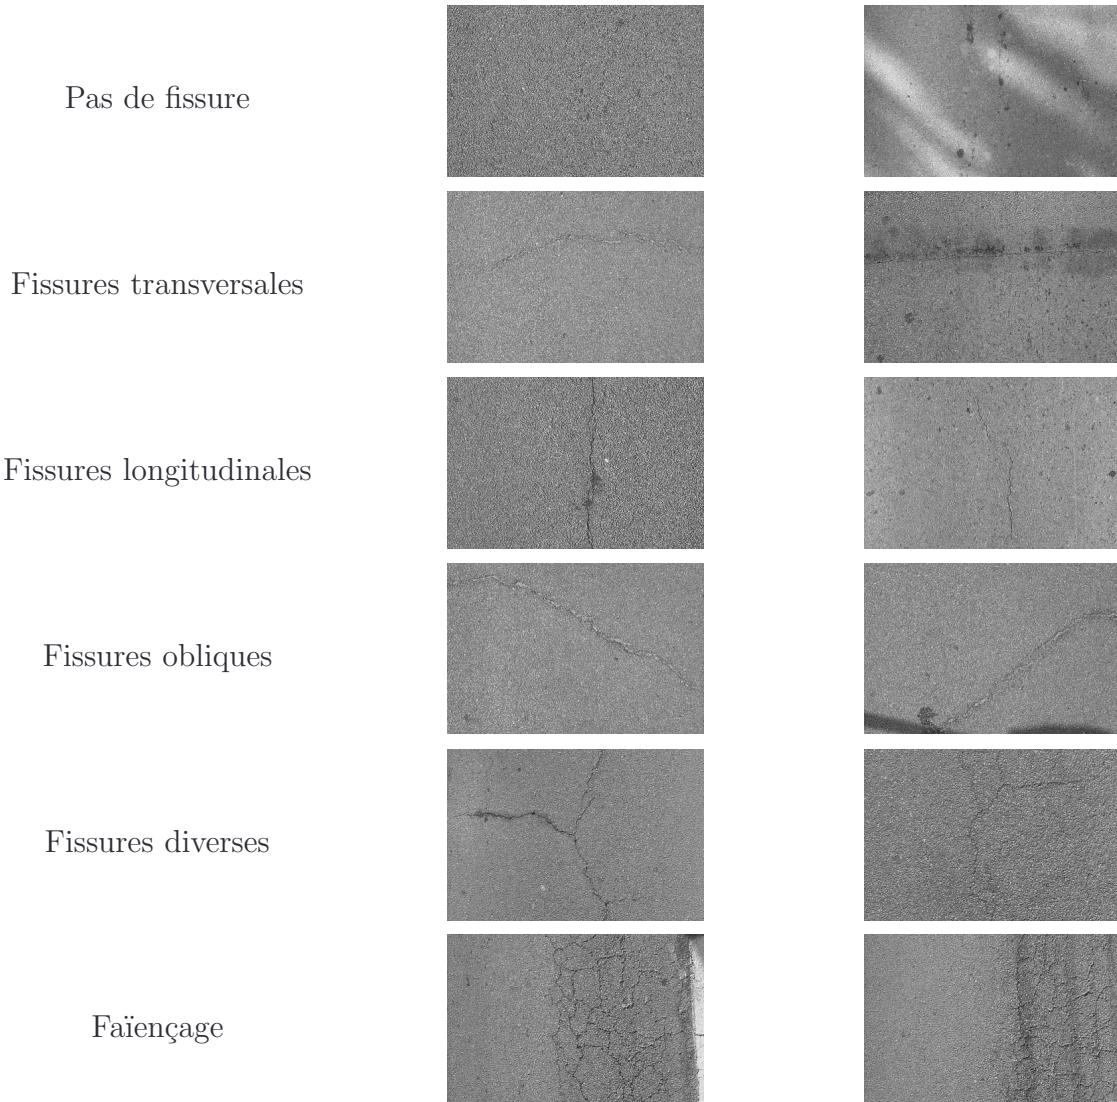


FIG. 1.1 – Exemple d’images de chaussées présentant des fissures – Nous distinguons différentes catégories de fissures en fonction de leur orientation et de leur concentration.

1.2 Phases de système de détection des fissures

Pour établir un système de détection automatique des fissures, trois étapes doivent être réalisées : acquisition des données, stockage des données et traitement des données. Chacune des ces étapes a son importance dans le système.

1.2.1 Acquisition des données

Cette étape est délicate car il faut prendre des images de bonne qualité (sans flou), pour avoir des résultats d'une bonne qualité avec un temps d'acquisition court et les conditions d'acquisition peuvent être très difficiles (intempéries, changements de luminosité, présence d'obstacles... etc). Divers systèmes ont été développés dans le monde, on cite les systèmes HARRIS, ADDA, ACM, DESYROUTE, GERPHO (voir annexe A). Ces systèmes possèdent des capteurs placés dans l'environnement routier dont le but est d'acquérir l'information à traiter (images des chaussées fissurées).

On note que, outre l'acquisition des données, certains systèmes ont été développés pour être capables de donner des résultats de détection : RAV, ADA, AMAC, l'ARAN ...etc (voir annexe A).

1.2.2 Stockage des données

Certains systèmes ont été développés en effectuant une réduction de la place occupée par l'image parce qu'il est nécessaire de stocker un grand nombre de données pour l'analyse. Dans ce contexte, trois approches ont été utilisées :

- Compression des images ;
- Quantification des images [Cheng 98, Chua 94] ;
- Stockage des images en niveaux de gris à la place de la couleur utilisée pour l'acquisition.

Dans tous ces cas, il y a une perte d'information et une possibilité de détérioration du signal de la fissure dans l'image, alors il est préférable de ne pas réduire la taille de l'image originale.

1.2.3 Traitement des données

C'est l'étape la plus importante pour notre étude et la plus difficile. Ce travail peut se diviser en cinq étapes successives à réaliser :

Pré-traitement des images – Dans certains cas, on peut observer des problèmes d'éclairage non constant dans les différentes zones de l'image, cf. exemple dans la figure 1.2. Par ailleurs, on rencontre des images où la texture de fond est non homogène et des images avec une fissure faiblement contrastée par rapport à la texture. Ces problèmes peuvent être traités par l'étape de pré-traitement comme l'application de filtre, par exemple le filtre passe-haut [Dumoulin 05], le filtre morphologique en niveaux de gris afin de réduire l'importance de la texture par rapport à la fissure [Dumoulin 05], le filtre médian [Shivprakash 05, Jitprasithsiri 96, Rababaah 05], le filtre gaussien [Rasse 02, Dumoulin 05]. D'autres méthodes utilisent le calcul de la moyenne locale pour corriger l'éclairage [Chua 94] et réalisent un seuil-

lage local et global basé sur cette moyenne pour enlever le bruit de fond. On mentionne également [Chou 95] qui utilise la logique floue (*fuzzy logic*) pour l'améliorer le contraste de l'image.

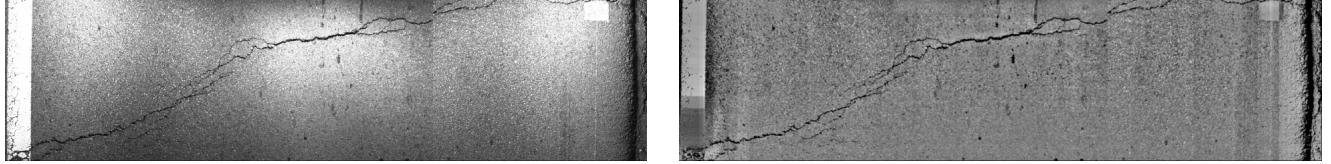


FIG. 1.2 – Image de la chaussée avec un éclairage non uniforme – À droite : pré-traitement de cette image par égalisation d'histogramme et lissage de l'image.

Binarisation – Dans cette étape une distinction des pixels correspondant à une fissure de ceux correspondant au fond est réalisée.

Segmentation – Les pixels obtenus à l'étape de binarisation sont regroupés afin de reconnaître des formes et détecter les défauts.

Post-traitement des résultats – Dans la plupart des méthodes de détection automatique des fissures, on obtient une image qui contient la fissure détectée mais également des points pixels correspondants au bruit. Afin d'obtenir un résultat plus fiable, on peut ajouter une étape de post-traitement. Parmi les post-traitements présents dans la littérature, on mentionne [Rasse 02] qui applique une segmentation locale autour du pixel étudié et [Nguyen 07] qui applique les outils de morphologie mathématique comme la dilatation, l'érosion, la fermeture et l'ouverture pour éliminer les petites régions qui ne correspondent pas à des fissures et [Subirats 06] utilise la transformation de Hough sur l'image résultat.

Classement des fissures – Cette étape concerne la caractérisation du défaut, c'est-à-dire de préciser le type de fissure (transversale, longitudinale, faînçage... etc) et quantifier la gravité de la fissure (position, taille).

On note que les étapes de pré-traitement de l'image et de post-traitement des résultats ne sont pas essentielles et ne sont pas toujours réalisées dans les méthodes de détection, mais dans certains cas elles sont nécessaires pour avoir des résultats plus fins [Nguyen 07, Rasse 02, Chou 95].

Notre travail porte essentiellement sur les deuxième et troisième étapes. Actuellement, ces deux étapes sont les plus importantes pour accomplir une détection automatique des fissures. Elles sont fortement liées l'une à l'autre. La plupart des méthodes ont besoin une bonne binarisation de l'image (bonne initialisation) pour donner un bon résultat après la segmentation. Cependant, nous souhaitons particulièrement mettre en œuvre une méthode qui donnera de bons résultats de segmentation même si l'initialisation n'est pas très bonne, c'est à dire une

méthode qui n'est dépend pas de l'initialisation. Cet aspect est très important car pour certaines images, il n'est pas possible d'avoir une bonne initialisation et alors nous aurons un mauvais résultat de la segmentation.

1.3 Méthodes actuelles

On peut distinguer trois familles de méthodes de détection des fissures : les méthodes par seuillage et morphologie mathématique, les méthodes par apprentissage et les méthodes globales. Nous décrivons les méthodes étudiées au LCPC (méthode par morphologie mathématique et par segmentation markovienne).

Méthodes par seuillage et morphologie mathématique

Les méthodes par seuillage sont les plus classiques, les plus anciennes et les plus populaires car elles sont simples à implémenter et peu coûteuses en temps de calcul.

On trouve un grand nombre de méthodes dans la littérature ayant comme but de trouver un seuil éventuel pour binariser l'image et détecter la fissure. On mentionne [Acosta 92] qui a travaillé sur l'analyse de l'histogramme pour détecter deux modes dans l'histogramme de l'image, un mode correspondant à la fissure et l'autre à la texture de fond. Nous présentons quelques images réelles avec leurs histogrammes dans la figure 1.3.

On peut constater qu'il est quasiment impossible de détecter la présence d'une fissure à partir de l'histogramme. D'autres auteurs ont utilisé une étude locale pour réaliser le seuillage comme [Jitprasithsiri 96, Koutsopoulos 93, Darwin 95, Meignen 97]. On peut citer aussi [Elbehri 05] qui a utilisé un seuillage adaptif. L'inconvénient de ces méthodes est qu'elles dépendent du choix du seuil, et les résultats contiennent de nombreuses fausses détections.

On peut utiliser des outils de morphologie mathématique pour connecter les portions de fissures détectées [Wang 02], ou pour éliminer les petites régions détectées [Nguyen 07] ou directement pour détecter les points appartenant à la fissure [Tanaka 98] (étape de binarisation). L'inconvénient des méthodes utilisant des outils de morphologie mathématique est qu'elles dépendent fortement du choix des paramètres tels que l'élément structurant, et elles ne prennent pas en compte la géométrie de la fissure (petits segments avec orientations).

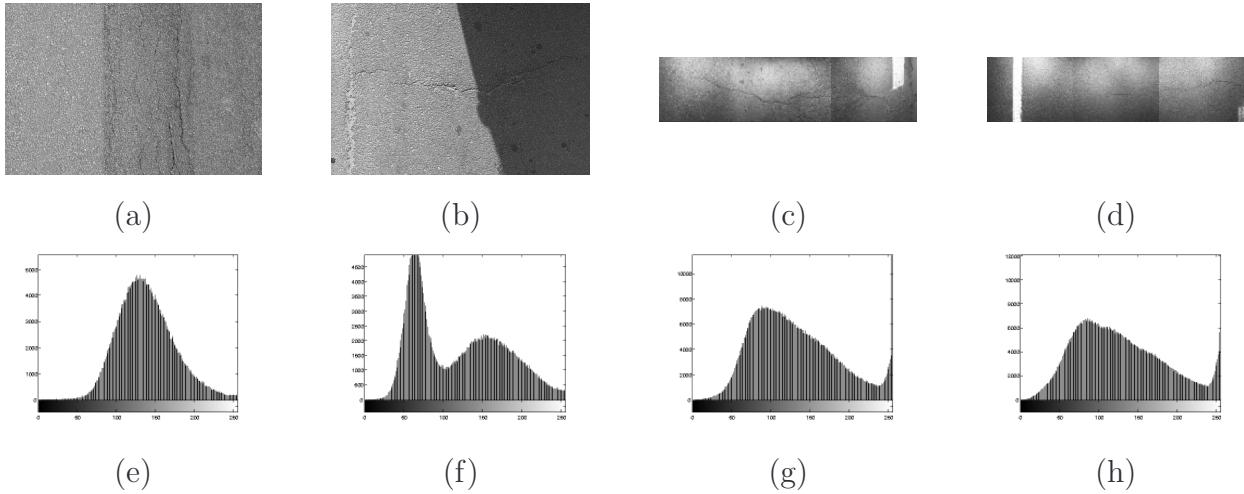


FIG. 1.3 – Quelques exemples d’images avec leurs histogrammes – On note qu’il n’apparaît pas de seuil précis et que les pixels appartenant à la fissure ne se distinguent pas dans l’histogramme de l’image. Dans l’image (a) on ne peut différencier qu’un seul mode. Dans l’image (b) on peut différencier deux modes mais ces modes ne correspondent pas à la fissure mais aux deux parties de l’image (une partie correspondant à l’ombre et une autre aux reste de l’image). Dans les images (c) et (d) on remarque que l’existence des marquages influence l’histogramme aussi.

1.3.1 Méthodes par apprentissage

Une grande nombre des méthodes de détection des fissures s’appuie sur des réseaux des neurones, ces qui comportent une étape d’apprentissage. Dans cette catégorie de méthodes, on peut citer le travail de [Cheng 01] qui utilise les statistiques de l’image pour aboutir à l’apprentissage du réseau de neurones et celui de [Verma 06] à deux réseaux de neurones : un jouant le rôle d’un classificateur entre images avec fissures est sans fissures, et un autre pour déterminer le type de défaut (fissure longitudinale, transversale … etc). Nous pouvons également citer le travail de [Ouellette 04].

L’inconvénient de ce type d’algorithmes est qu’ils nécessitent l’étape d’apprentissage afin de fixer les paramètres du système ce qui n’est pas évident à mettre en œuvre dans le cadre de l’application visée.

1.3.2 Méthodes globales

Ces méthodes ont des méthodes qui s’appuient sur un traitement de l’image selon des caractéristiques globales de fissure et de texture. Dans cette catégorie on peut citer l’approche de [Augereau 01] qui utilise une méthode par EDP (équations aux dérivées partielles) pour transformer la surface bruitée de l’image de chaussée en espace-échelle afin d’éliminer les per-

turbations. Cette méthode utilise les propriétés différentielles de la fissure en utilisant la notion de courbure. La méthode consiste donc à appliquer un filtrage Laplacien pour résoudre ces équations.

Une approche qui est basée sur une étude de la texture et qui traite la fissure comme un bruit dans une texture donnée peut être ajoutée à cette catégorie des méthodes. On peut utiliser une transformation de Walsh de l'image [Petrou 96], ou une transformation basée sur la distribution de Wigner [Song 95] pour faire cette étude des caractéristiques de la texture. Chaque région de l'image qui n'a pas ces caractéristiques est considérée comme appartenant à la région du bruit, c'est-à-dire une fissure.

On peut citer l'approche qui utilise une transformation en ondelettes [Chambon 09, Subirats 06, Wang 02, Zhou 05, Delagnes 95].

1.3.3 Méthodes comparées

Au sein du LCPC deux méthodes ont été développées, une méthode basée sur des outils de morphologie mathématique et une autre basée une transformation en ondelettes combinée avec une modélisation markovienne. Nous expliquons brièvement ces deux méthodes car finalement nous souhaitons comparer les résultats d'une méthode proposée avec celles par ces deux méthodes.

Méthode par morphologie mathématique

Cette méthode commence par une étape de pré-traitement en utilisant soit une érosion, soit un filtrage médian, soit une égalisation de l'histogramme pour augmenter le contraste des fissures par rapport au fond. Puis on réalise une étape de binarisation par seuillage local. L'étape de segmentation correspond à une analyse de la forme et de la taille de composantes connexes. On vérifie un certain nombre de règles (issues de la connaissances des releveurs sur les défauts de la chaussée), comme, par exemple, le fait que chaque composante avec une taille plus petite qu'un seuil fixé ne peut être une fissure. La figure 1.4 est un exemple des résultats par cette méthode.

Méthode par transformation en ondelettes avec modélisation markovienne

L'originalité de ce travail est le calcul d'une ondelette mère adaptée à chaque texture de chaussée analysée [Chambon 09, Subirats 06]. Brièvement, les étapes de la méthode étudiée au sein de LCPC sont les suivantes :

1. Spécification du nombre d'échelles et angles représentatifs de la fissure ;

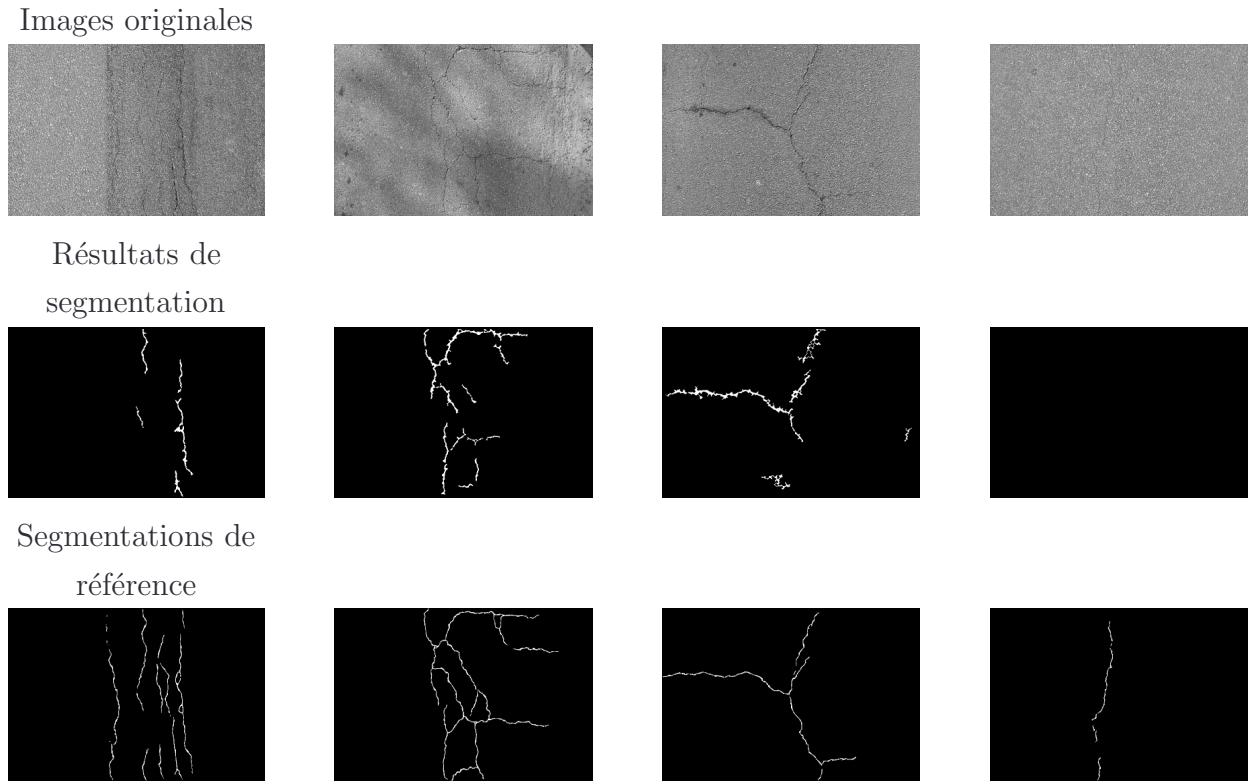


FIG. 1.4 – Images de résultats par la méthode à base de morphologie mathématique – Cette méthode ne présente pas beaucoup de fausses détections mais, la localisation est très peu précise, incomplète et, dans le dernier cas, la fissure n'a pas du tout été détectée.

2. Application d'un filtre adapté à la texture de l'image pour chaque échelle et chaque orientation (on suppose que la fissure peut avoir 4 orientations différentes) ;
3. Binarisation de l'image (seuillage qui ne concerne que 5% de l'image) ;
4. Segmentation par modèle markovien pour chaque échelle ;

Pour l'étape à l'échelle $n + 1$ (plus fine que n), on initialise la segmentation avec le résultat à l'échelle n .

L'intérêt de cette méthode réside dans l'introduction de contraintes de voisinage et la prise en compte de contraintes locales dans un contexte global. Le pixel ne sera pas pris en compte comme une entité seule, mais il sera considéré par ses interactions locales avec ses pixels voisins. Dans l'approche proposée, la cohérence des orientations et de connexité entre pixels (ou sites) est prise en compte. Ce qui a encouragé l'exploration d'une nouvelle méthode basée sur la modélisation markovienne qui surmonte les limites de cette méthode, et tire profit des avantages de cette modélisation.

La figure 1.5 montre les résultats obtenus par la méthode par filtrage adapté combinée avec une segmentation markovienne [Chambon 09] pour les images (a, b, d) de la figure 1.3. Ces résultats montrent les limites de cette méthodes. L'image (a) contient une fissure d'une largeur minces; le résultat montre beaucoup des fausses détections où il apparaît de nombreux petits segments qui ne correspondent pas à la fissure. Pour l'images (b) et (c) on note comment l'existence de l'ombre et l'éclairage affecte les résultats finals.

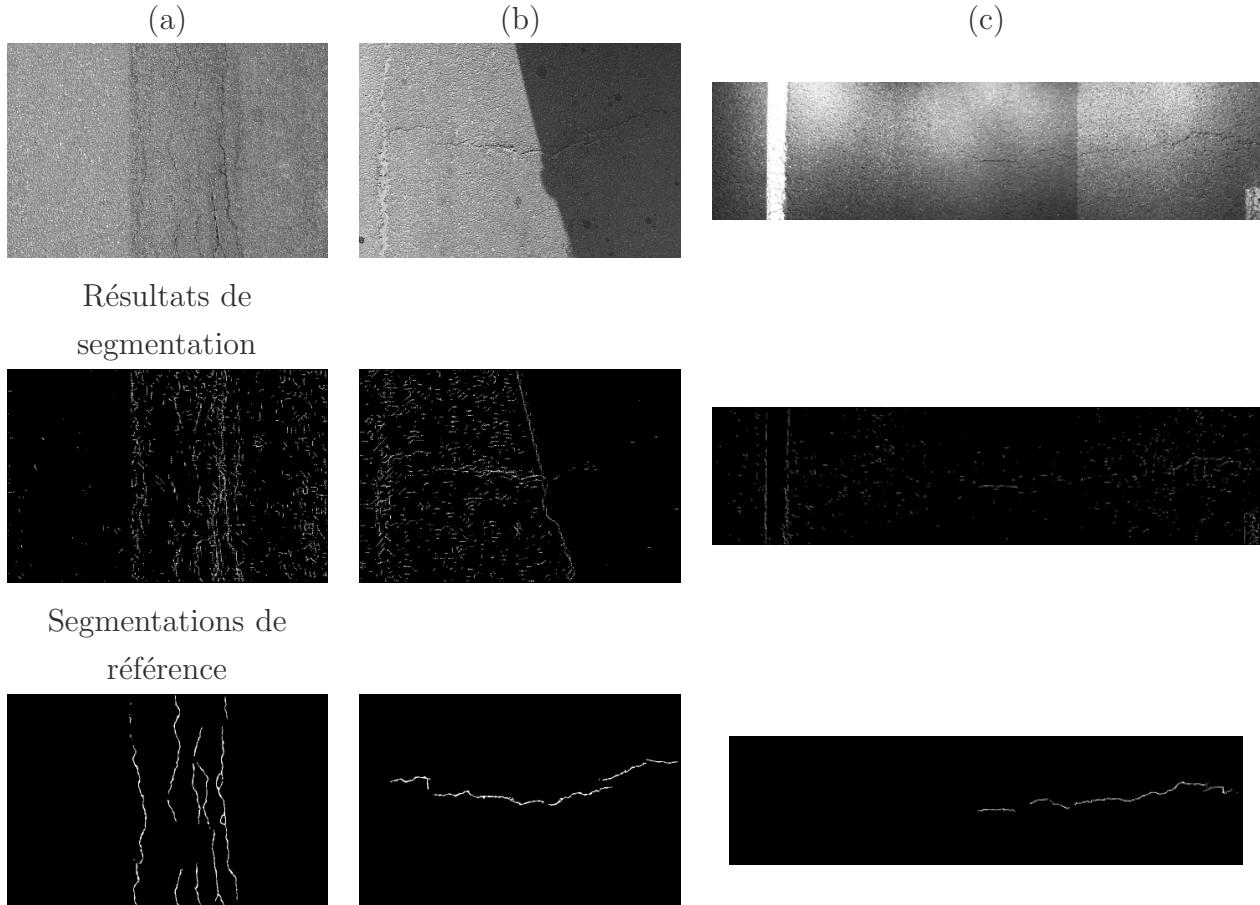


FIG. 1.5 – Résultats de segmentation obtenus avec la méthode par filtrage adapté [Chambon 09] – Nous présentons un cas où la méthode se comporte moins bien que la méthode par morphologie mathématique, cf. figure 1.4. Nous présentons également deux cas illustrant les limites de la méthode, c'est-à-dire, les difficultés face aux ombres ou aux problèmes d'éclairage.

Dans le chapitre suivant, nous passons à la description de l'image dans le cadre d'une modélisation markovienne afin d'entamer une description de notre méthode basée sur cette modélisation.

Chapitre 2

Segmentation par modélisation markovienne

Dans le cadre de la segmentation, tâche qui consiste à extraire des partitions de l'image (où des régions de pixels connexes) ayant des propriétés communes, le niveau de gris en chaque pixel n'est pas la seule information utilisée mais les interactions avec les pixels voisins interviennent également. Cette propriété va nous permettre d'utiliser un formalisme markovien. Le principe est de définir des énergies locales entre groupes des sites (pixels) reflétant les interactions entre niveaux de gris.

Dans ce chapitre, afin d'aborder le problème de la segmentation, nous introduisons tout d'abord les notions fondamentales du formalisme markovien (site, clique, voisinage, énergies locale et globale) avant de définir plus formellement un champ de Markov et un champ de Gibbs et d'énoncer le théorème d'Hammersley Clifford : théorème d'équivalence entre ces deux champs. Ces notions nous permettent de décrire la segmentation dans un cadre bayésien.

2.1 Sites, cliques et voisinages dans une image

Dans le cadre de la modélisation markovienne, l'image est considérée comme un ensemble fini S de sites s_i correspondant à un pixel ou un ensemble de pixels connexes. Le terme S est donc un réseau discret fini, partie de \mathbb{Z}^d , si on note d la dimension de l'espace (2 pour l'image, 3 pour les volumes). À chaque site de l'image est associé un descripteur, qui correspond à l'état du site et qui peut être son niveau de gris, une étiquette, ou une information plus complexe. La notion d'interactions locales nécessite de structurer les relations entre les différents sites de l'image. Pour ce faire, on muni S d'un système de voisinage V_s défini de la façon suivante.

$$V_s = \left\{ s' / s \notin V_s \text{ & } s' \in V_s \Rightarrow s \in V_{s'} \right\} \quad (2.1)$$

À partir de ce système de voisinage on peut définir le système de cliques C : une clique associée à un voisinage est soit un singleton de S , soit un ensemble de sites mutuellement voisins. Le système de cliques dépend du système de voisinage utilisé, cf. Figure 2.1. On note C_k l'ensemble des cliques d'ordre k .

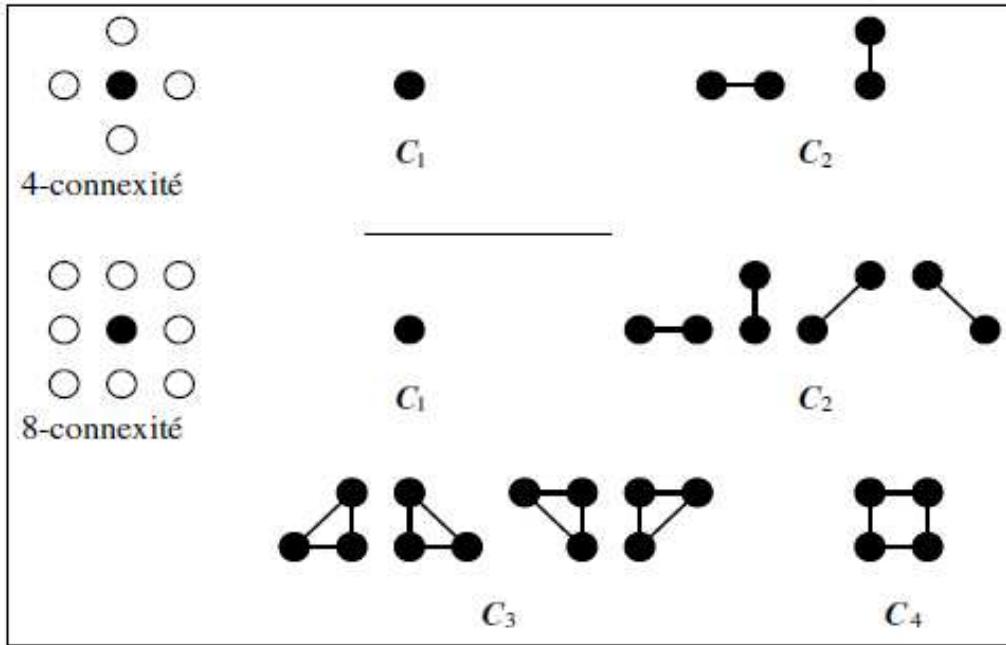


FIG. 2.1 – Cliques associées à deux systèmes de voisinage en dimension 2 – Les configurations que l'on trouve dans la partie supérieure de la figure correspondent à un voisinage de type 4-connexe, les cliques associées à ce système sont d'ordre 1 et 2. Les autres configurations correspondent à un système de voisinage 8-connexe avec ses cliques associées. L'ordre des cliques varie de 1 à 4. On remarque que la complexité du système de cliques dépend du voisinage utilisé et il peut être choisi en fonction de l'application.

2.2 Notions d'énergies locale et globale

Les interactions locales entre les descripteurs des sites voisins s'expriment comme une énergie de clique. On associe un potentiel U_c à une clique c , ce potentiel dépend des descripteurs des pixels constituant la clique. On définit l'énergie globale de l'image qui est la somme des potentiels de toutes les cliques :

$$U = \sum_{c \in C} U_c \quad (2.2)$$

De plus, l'énergie locale en un site s est la somme des potentiels de toutes les cliques auxquelles il appartient :

$$U_s = \sum_{c \in C / s \in c} U_c \quad (2.3)$$

Notons que le potentiel d'une clique et les énergies locale et globale sont souvent appelées le coût d'une clique et les coûts locale et globale respectivement.

Nous avons jusqu'ici considéré les notions de base qui nous permettent, par la suite, de définir un champ de Markov, un champ de Gibbs et le théorème exprimant la relation entre ces deux pour aborder la façon d'évaluer les interactions locales entre les sites de l'image et décrire comment ces interactions interviennent dans le problème de la segmentation dans le cadre bayésien.

2.3 Définition d'un champ de Markov

Pour définir un champ markovien on s'appuie sur une modélisation probabiliste de l'image. L'image est considérée comme une réalisation d'un champ aléatoire. Soit s un site de l'image, on lui associe une variable aléatoire X_s prenant ses valeurs dans E . Le descripteur x_s en s est une réalisation de X_s . On définit alors le champ aléatoire $X = (X_s, X_t, ..)$ prenant ses valeurs dans $\Omega = E^{|S|}$. Dans ce cadre probabiliste, l'image considérée est une réalisation x du champ. Les probabilités conditionnelles locales d'une valeur en un site permettent de mesurer le lien statistique entre un descripteur et le reste de l'image. L'hypothèse markovienne permet d'évaluer ces quantités.

Notons x_s la valeur du descripteur prise au site s et $x^s = (x_{s'})_{s' \neq s}$ la configuration de l'image excepté le site s . La définition d'un champ de Markov est alors la suivante :

Un champ aléatoire X est dit markovien si et seulement si la probabilité conditionnelle d'un site ne dépend que de son voisinage.

$$P(X_s = x_s / x^s) = P(X_s = x_s / x_{s'}, s' \in V_s) \quad (2.4)$$

Ainsi, le descripteur en un site ne dépend que des descripteurs des sites voisins de ce site.

2.4 Théorème de Hammersley-Clifford

La modélisation markovienne prend toute sa puissance grâce au théorème que nous allons voir maintenant. En effet, celui-ci permettra d'accéder aux expressions des probabilités conditionnelles locales. Il nous faut au préalable définir le champ de Gibbs.

Définition d'un champ de Gibbs – Le champ de Gibbs de fonction d'énergie $U(x) : \Omega \rightarrow \mathbb{R}$ est la probabilité P définie sur Ω par :

$$P(X = x) = \frac{1}{Z} \exp(-U(x)) \quad (2.5)$$

où $U(x) = \sum_{c \in C} U_c(x)$, $U_c(x) = U_c(x_j, j \in c)$, C est le système de cliques associé à un voisinage V .

et Z est la constante de normalisation appelée fonction de partition de Gibbs et elle est définie par :

$$Z = \sum_{x \in \Omega} \exp(-U(x)) \quad (2.6)$$

En pratique, il est quasi impossible de calculer Z à cause du très grand nombre de configurations globales possibles (sommation sur tous les configurations dans Ω). Par exemple, si on prend le cas d'une image binaire (deux classes) de taille $= 512 \times 512$, on a $\text{card}(\text{card}\Omega) = 2^{512 \times 512}$ configurations possibles ! On va voir dans la section suivante que dans le cadre bayésien, en utilisant ce théorème, on n'a pas besoin de calculer toutes ces configurations.

L'expression de l'équation (2.5) permet d'exprimer l'énergie globale d'un champ de Gibbs. Cette énergie possède la propriété de se décomposer sous forme d'une somme d'énergies locales, cf. équation (2.2).

Notons ici que plus une configuration d'un champ de Gibbs a une énergie faible, plus elle est probable.

Théorème – Ce théorème proposé dans [Besag 74] donne la relation entre les champs markovien et gibbsien, ce qui permet d'exprimer la probabilité d'une configuration d'un champ de Markov en utilisant les énergies locales des sites de l'image. Sous les hypothèses suivantes :

- S est fini ou dénombrable ;
- le système de voisinage V est borné ;
- l'espace d'état E est discret.

$\forall \mathbf{x} \in \Omega, P(\mathbf{X} = \mathbf{x}) > 0, X \text{ est un champ de Markov relativement à un voisinage } V \iff X \text{ est un champ de Gibbs d'énergie associée à } V.$

Cette équivalence entre ces champs permet dans le cadre bayésien que nous décrivons dans la section suivante d'accéder aux probabilités conditionnelles, aux champ d'intérêt et éventuellement d'obtenir la configuration optimale qui est la solution souhaitée au problème de segmentation.

2.5 Segmentation dans le cadre bayésien

Nous avons présenté dans la section précédente la définition d'un champ de Markov dans le cadre du traitement d'images. Nous abordons ici son utilisation pour une application très connue en traitement d'images : la segmentation. Pour cette application, nous nous plaçons dans le cadre bayésien. L'image est modélisée par deux champs aléatoires dans ce cadre :

- $X = (X_s)_{s \in S}$, le champ des étiquettes, dans le cas de segmentation des images de chaussées fissurées, ce champ est binaire. Pour un site donné s , $x_s = 1$ indique la présence d'une fissure et $x_s = 0$ indique que la site appartient à la texture du fond ;
- $Y = (Y_s)_{s \in S}$, le champ des observations, dans notre cas il peut prendre les valeurs des niveaux de gris. $\forall s \in S, Y_s \in \mathbb{R}$

Sachant que les réalisations de X sont inobservables, le but est d'estimer $X = x$ à partir de l'observation $Y = y$. C'est la raison pour laquelle, il est confortable de se placer dans un cadre bayésien. Dans notre cas, il s'agit d'identifier la position de la fissure dans l'image de la chaussée et d'attribuer l'étiquette 1 aux sites appartenant à la fissure et 0 aux sites appartenant au fond. Le cadre bayésien présente plusieurs estimateurs dans ce contexte, comme, par exemple, l'estimateur MAP (maximum de vraisemblance *a posteriori*), MPM (maximum *a posteriori* de la marginale) et TPM (*Threshold Posteriori Mean*) [Sigelle 99]. Nous décrivons l'estimateur MAP parce que c'est l'estimateur que nous allons utiliser dans notre travail par la suite.

En supposant qu'on connaît les quantités suivantes :

- La densité de probabilité *a priori* de X notée $P(X)$ qui résume l'information dont on dispose sur le champ X ;
- La densité de probabilité conditionnelle – loi *a posteriori* – $P(X = x | Y = y)$;

Le champ des descripteurs estimé \hat{x} sera donné par la valeur qui maximise la probabilité *a posteriori* :

$$\hat{x}_{MAP} = \operatorname{argmax}(P(X = x | Y = y)) \quad (2.7)$$

La relation de Bayes indique que :

$$(P(X = x | Y = y)) = \frac{(P(Y = y | X = x)) P(X = x)}{P(Y = y)} \quad (2.8)$$

Y étant l'observation $\rightarrow P(Y = y)$ est une constante et n'influence pas l'estimation de X , alors :

$$\hat{x}_{MAP} = \operatorname{argmax}(P(Y = y | X = x)) P(X = x) \quad (2.9)$$

On suppose que le champ des étiquettes est markovien, donc d'après le théorème d'Hammersley-Clifford le champ des étiquettes X suit une distribution de Gibbs, et alors selon l'équation (2.5) le terme *a priori* sera :

$$P(X = x) = \frac{1}{Z} \exp(-U_1(x)) \quad (2.10)$$

avec

$$U_1(x) = \sum_{c \in C} U_c \quad (2.11)$$

où C est l'ensemble des cliques c d'ordre supérieur à 1 sur le graphe considéré, et U_c représente les fonctions désignant les fonctions de potentiel associées aux cliques c de C . On appelle $P(X = x)$ le terme *a priori*. Il s'appelle également le terme de réguralisation. Pour un problème de segmentation spécifique, la définition de ce terme est équivalente à la définition de la fonction d'énergie U_1 . Ce terme reflète les propriétés qu'on souhaite respecter dans la segmentation. On remarque que c'est l'énergie globale de l'image. C'est ce qu'on appelle le coût global de l'image. Ce coût global peut être décomposé en coûts locaux (fonctions de potentiels). Rappelons que le coût local en un site est la somme de tous les coûts associés aux cliques qui apparaissent dans le voisinage défini, cf. équation (2.3).

En supposant que la probabilité est positive on peut poser :

$$U_2(x, y) = -\ln(P(Y = y/X = x)) = \sum_{s \in S} u_2(s) \quad (2.12)$$

alors,

$$P(Y = y/X = x) = \exp(-U_2(x, y)) = \exp\left(-\sum_{s \in S} u_2(s)\right) \quad (2.13)$$

U_2 est une fonction d'énergie associée à la probabilité du champ des observations conditionnellement au champ des étiquettes. Le terme $P(Y = y/X = x)$ est appelé le terme d'attache aux données, car il est relié seulement au champ des données (observations). Comme pour le terme *a priori*, la définition de ce terme est équivalente à la définition de la fonction d'énergie associée à celui-ci. Ce terme modélise la texture de l'image.

Alors, le champ estimé devient :

$$\hat{x}_{MAP} = \operatorname{argmax}(\exp(-U_1 - U_2)) \iff \hat{x}_{MAP} = \operatorname{argmin}(U_1 + U_2) \quad (2.14)$$

À partir de cette expression, on déduit que l'estimation du champ des étiquettes est définie par les fonctions d'énergie U_1 et U_2 et le système de voisinage V qui est associé à un système de cliques. La configuration souhaitée (résultat de la segmentation) est celle qui a l'énergie minimale parmi toutes les configurations possibles. Il faut choisir une méthode d'optimisation pour obtenir cette configuration minimale. La littérature présente deux algorithmes d'optimisation pour le critère MAP : une méthode optimale globalement, le recuit simulé, et une méthode optimale localement, ICM (*Iterated conditional modes*) [Besag 86].

On note que dans les plupart des cas, les fonctions d'énergie sont dépendantes des paramètres spécifiques (par exemple le paramètre β dans le modèle d'Ising, voir Annexe (B.1)). Il faut estimer ces paramètres de sorte que l'estimation du champ des étiquettes est considérée totalement bayésienne.

Maintenant, afin de résumer les aspects dont nous avons besoin pour notre travail, nous pouvons avancer que l'utilisation des champ de Markov pour résoudre un problème de segmentation nécessite la mise au point de plusieurs briques, comme suit :

Modélisation – Cela concerne la définition du modèle *a priori* qui reflète notre connaissances sur la solution dans les approches bayésiennes et celle du modèle de texture (terme d'attache aux données). Il s'agit de définir les cliques et les potentiels associés.

Estimation des paramètres – Nous considérons ici l'estimation des paramètres associés au modèle de la texture et au modèle *a priori*. Dans ce contexte plusieurs méthodes ont été proposées. Nous mentionnons les méthodes fondées sur un critère de maximum de vraisemblance pour l'estimation des paramètres de mélange de distributions de gaussienne *via* l'algorithme d'Espérance-Maximisation (EM) et un méthode utilisant l'hypothèse contextuelle inhérente proposés dans [Descombes 97b].

Simulation, Optimisation – Une fois le modèle défini, les paramètres sont estimés ou établis empiriquement, le résultat de segmentation recherché est une configuration qui optimise un certain critère bayésien. Ce critère peut être le MAP, le MPM ou le TPM. Si le critère est le MAP, alors on cherche une configuration qui maximise la probabilité *a posteriori*. Pour obtenir cette configuration nous avons recours à un algorithme d'optimisation. Si le critère est le MPM ou le TPM alors des solutions algorithmiques sont présentes dans la littérature [Sigelle 99].

Chapitre 3

Application d'une méthode par modélisation markovienne aux images de chaussées

Il existe de très nombreux papiers qui s'appuient sur une segmentation basée sur les champs de Markov en traitement d'images. Parmi ces articles, un certain nombre permettent de reconnaître des objets fins, comme, par exemple :

- en imagerie médicale : segmentation des vaisseaux sanguins [A.Pourmorteza 08, Simò 01] et segmentation des images du cerveau ;
- en imagerie SAR (*Synthetic aperture Radar*) : détection du réseau routier [Katartzis 00, Tupin 98, Yong 08], détection des objets lignes [Hellwich 96], détection des filaments dans des images de mer gelée [Yu 06] et détection du littoral [Descombes 96]) ;
- en imagerie radiographique : détection des fissures longitudinales dans des tubes en acier [Alekseychuk 07].

De plus, les modèles markoviens peuvent être intégrés dans n'importe quel problème de segmentation : chien-modèle [Descombes 95, Descombes 97a] et *boundary model* [Wu 07].

Nous classons les méthodes à base de modélisation markovienne que nous avons étudiées dans ces papiers en deux classes : les méthodes spécifiques et les méthodes génériques. Cette classification nous a aidé à choisir le modèle markovien de base à utiliser et à adapter à la segmentation des fissures dans des images de chaussées.

- *Méthodes spécifiques* – Ces méthodes prennent en compte la spécificité de l'image à segmenter. Par exemple dans [Hellwich 96], l'auteur utilise le fait que les scènes SAR semblent parfois invisibles à cause de l'azimut des radiations incidents [Hendry 98] et il utilise une connaissance spécifique sur ces scènes pour modéliser le terme *a priori*.

Dans [Alekseychuk 07] les images traitées sont des images radiographiques. Dans ces images la méthode de détection prend en compte cet aspect en prenant en considération les propriétés de fissure dans une image radiographique (l'image radiographique des fissures dépend fortement sur leurs orientation par rapport à la direction de radiation de x-ray). Dans [Simò 01] la segmentation concerne plusieurs objets : les vaisseaux sanguins, la fovéa et les veines. Dans cette modélisation, on prend en compte le fait que la fovéa doit se trouver au centre de l'œil (donc de l'image).

Même si une analogie peut être faite entre ces spécificités et les spécificités des fissures des chaussées, nous préférons adopter un modèle plus générique (et éventuellement de l'adapter).

- *Méthodes génériques* – Ces méthodes ne prennent pas en compte des informations associées au type de l'image, et peuvent être utilisées pour n'importe quel problème de segmentation et n'importe quelle image. Dans [Yu 06] le modèle proposé pénalise directement le problème de détection des fissures. La différence entre notre problématique et celle de celui-ci est que le fond ici a une texture moins forte que la texture de l'image de chaussée et que la classification est multi-classes (multiclasses : les fissures et le fond correspondent à différentes classes suivant les différents types de glaces). *A priori*, cette méthode n'est pas adaptée au problème que nous nous posons : détecter deux classes : la fissure et le fond qui est très fortement texturé.

Dans [Wu 07], l'originalité de ce travail est la modélisation du terme *a priori* par deux champs de Markov : un modèle pour les régions et un autre pour les frontières. Alors, l'énergie correspondante définit l'interaction entre ces deux champs. Parmi les différentes configurations possibles de combinaisons de ces champs, un nombre de cas préférables est gardés et les autres sont pénalisés. L'intérêt de ce modèle est que les configurations préférables prennent en compte la présence d'une région de 1 et 2 pixels de largeur, ce qui dans le cas de la segmentation des fissures peut être utile.

Dans [Descombes 95], l'auteur propose un modèle *a priori* binaire (deux classes) adaptable à la présence des structures fines et de bruit dans l'image. Cet aspect est le plus important pour notre problématique, car la difficulté de la segmentation des fissures dans l'images des chaussées réside dans le fait que ce sont des objets très fins sur un fond texturé, très bruité.

Parmi tous les modèles markoviennes que nous avons étudiés, le chien-modèle est le seul qui pénalise directement la présence de bruit dans l'image en attribuant un coût élémentaire aux configurations locales prédéfinies comme bruit. Il utilise un système de cliques qui permet d'explorer des interactions d'ordre supérieur entre les sites de l'image et alors d'explorer un plus grand voisinage qui est utile pour mieux pénaliser le bruit.

Le *boundary model* et le chien-modèle nous semblent les plus adaptables à notre problématique. Entre ces deux, le chien-modèle est plus adaptable à la présence de bruit. C'est pourquoi on trouve que le chien-modèle comme un modèle *a priori* dans une modélisation markovienne constitue une base solide pour la mise en œuvre d'une méthode automatique pour la détection des fissures.

La table 3.1 montre notre classification entre les méthodes que nous avons étudiées.

MÉTHODES SPÉCIFIQUES	MÉTHODES GÉNÉRIQUES
[A.Pourmorteza 08, Simò 01, Hellwich 96, Yu 06, Katartzis 00, Tupin 98, Yong 08]	[Descombes 95, Wu 07, Yu 06]

TAB. 3.1 – Classification des méthodes de détection des objets fins – Nous nous contentons d'énumérer les méthodes mises en œuvre dans le cadre de la détection des objets fins dans le contexte de la segmentation. Ces méthodes traitent des problématiques semblables à la problématique de segmentation des fissures.

3.1 Modèle

Dans le chapitre 2, section 2.5, nous avons cité les aspects nécessaires pour la traitement d'un problème de segmentation dans le cadre de la modélisation markovienne. Nous abordons maintenant chacun de ces aspects pour le problème de la segmentation des fissures dans des images de chaussées. Dans la section suivante, nous présentons le chien-modèle comme un modèle *a priori* adapté à notre problème. Pour ce modèle nous décrivons la manière dont les cliques sont choisies, puis nous décrivons comment calculer le coût local d'un site dans ce modèle.

On note que le code de ce modèle a été fournie par l'auteur à nous.

3.1.1 Chien-modèle

Le modèle d'Ising/Potts souvent utilisé dans les problèmes de segmentation n'est pas satisfaisant en terme de régularisation [Morris 96] à cause de son comportement complexe trop dépendant de la valeur de son paramètre β (cf. Annexe B), ce qui a encouragé l'étude d'autres modèles de Markov plus adéquats pour la segmentation d'images comme le chien-modèle. Ce modèle a été proposé dans [Descombes 95] comme un modèle pour la restauration d'images et

la segmentation binaire (deux classes), et a été généralisé pour les cas m-aire (plusieurs classes). À part ces deux applications, il est intervenu dans de nombreuses applications comme l'analyse spatio-temporelle d'IRMf [Descombes 98] et la modélisation du taux de distorsion [VETRO 03]. L'idée principale de ce modèle est de prendre en compte les contours et les lignes, tout en prenant en compte le bruit présent dans l'image. Pour la discrimination entre les contours, les lignes et le bruit, ce modèle associe un coût élémentaire par unité de longueur pour chacune de ces configurations :

- un coût n associé au bruit ;
- un coût l associé à une ligne ;
- un coût e associé à un contour ;

Le système de cliques est composé d'une fenêtre 3×3 , avec un système de voisinage de taille 5×5 . Avec une clique 3×3 , il y a $2^9 = 512$ configurations. Ces configurations sont classées en 51 classes notées $C(i)$, $i \in \{1, \dots, 51\}$. Le classement de ces configurations est obtenu en considérant que deux configurations sont équivalentes par rotation et/ou par inversion (noir \leftrightarrow blanc), cf. table 3.3. Un potentiel $V_c(i)$ est associé à chacune de ces classes. Ces potentiels sont calculés en modélisant des contraintes sur les objets représentants les lignes, les contours et le bruit. On peut distinguer 8 orientations différentes de configurations associées à ce modèle : horizontale (0°), verticale (90°), diagonale ($45^\circ, 135^\circ$) et oblique ($22.5^\circ, 67.5^\circ, 112.5^\circ, 157.5^\circ$)

Les contraintes sur les contours et lignes sont établis en modélisant des équations qui traduisent les combinaisons des configurations des cliques qui localement, nous donnent des portions des contours ou des lignes ayant des orientations spécifiques.

Contraintes sur les contours :

La figure 3.1 illustre les combinaisons de configurations qui nous donnent les contraintes associées aux contours.

Contours verticaux :

$$2C(13) = e \quad (3.1)$$

Contours diagonaux :

$$2C(3) + 2C(14) = \sqrt{2}e \quad (3.2)$$

Contours obliques :

$$C(5) + C(29) + C(3) = \frac{\sqrt{5}}{2}e \quad (3.3)$$

Contraintes sur les lignes :

La figure 3.2 illustre les combinaisons de configurations qui nous donnent les contraintes associées aux contours.

Lignes verticales (et horizontales) :

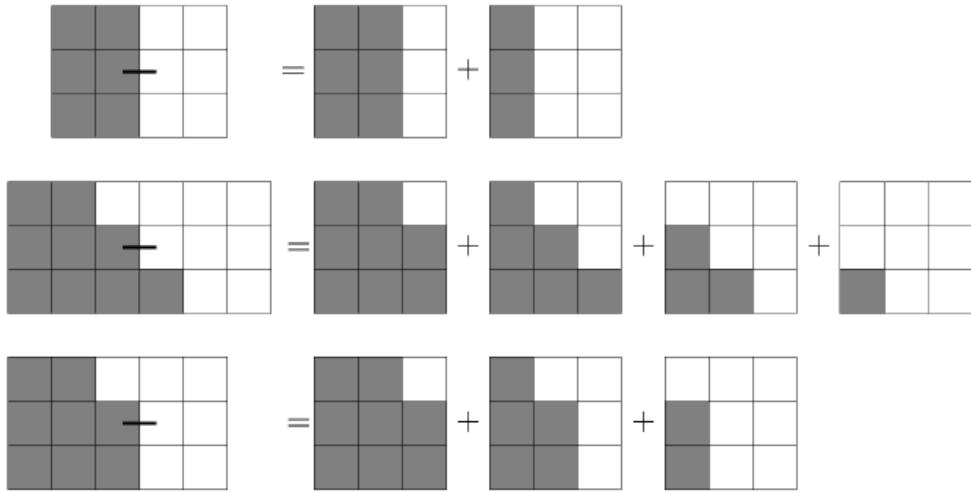


FIG. 3.1 – Équations associées aux contours pour le chien-modèle – La première ligne du schéma correspond à l'équation associée aux contours verticaux. La deuxième correspond à celle associée aux contours diagonaux et la dernière correspond aux contours obliques. Nous nous référerons à la table 3.3 pour connaître la classe de chaque configuration.

$$2C(13) + C(26) = l \quad (3.4)$$

$$4C(13) = 2e \quad (3.5)$$

Lignes diagonales :

$$2C(3) + 2C(11) + C(28) = \sqrt{2}l \quad (3.6)$$

$$2C(3) + 2C(14) + 2C(35) = 2\sqrt{2}e \quad (3.7)$$

$$2C(3) + 4C(14) + C(9) = 2\sqrt{2}e \quad (3.8)$$

Lignes obliques :

$$C(3) + C(16) + C(23) + C(5) = \frac{\sqrt{5}}{2}l \quad (3.9)$$

$$C(3) + C(29) + C(19) + C(5) = \sqrt{5}e \quad (3.10)$$

$$2C(5) + 2C(29) + 2C(3) = \sqrt{5}e \quad (3.11)$$

En résolvant ce système, on obtient les valeurs des potentiels associées aux classes en fonction des coûts élémentaires (n , l et e). Tous les potentiels qui n'interviennent pas dans le système d'équations sont considérés comme du bruit et alors on associe le coût n , cf. table 3.3. En se référant à la table 3.3, on peut calculer le coût local d'un site :

$$u_1(s) = \sum_{c \in C(i)/s \in c} V_c^b(i) / i \in \{1, \dots, 51\} \quad (3.12)$$

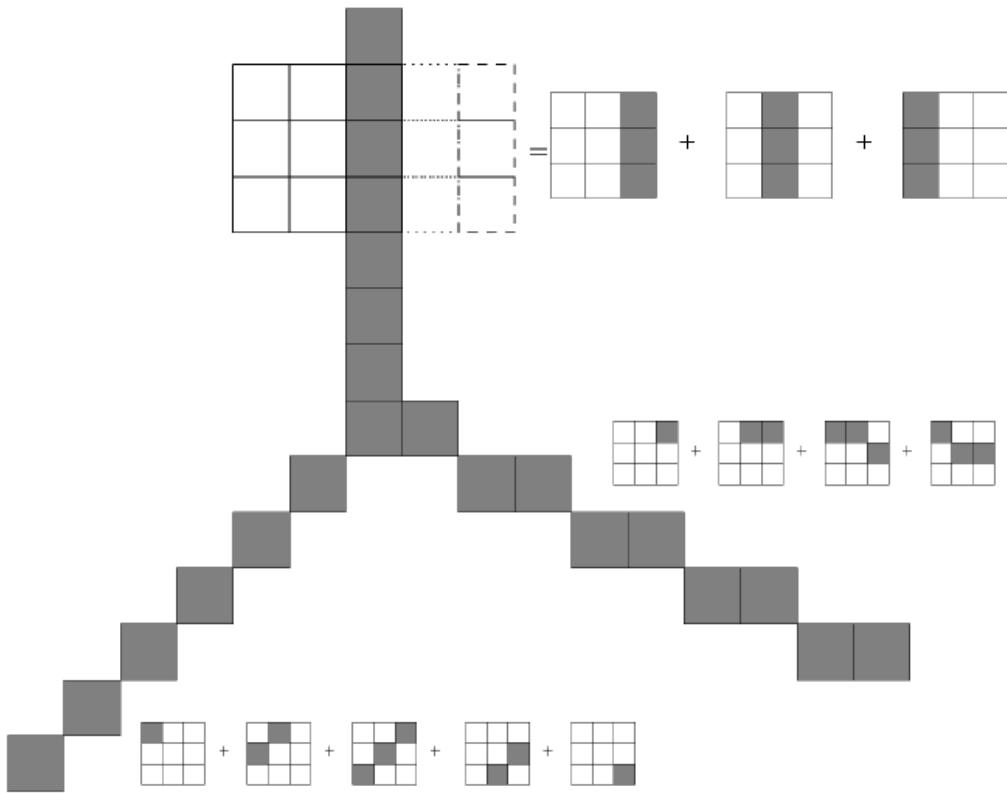


FIG. 3.2 – Équations associées aux lignes pour le chien-modèle.

Notons que dans un voisinage de 5×5 , avec un système de cliques de 3×3 , un site appartient à 8 cliques.

3.1.2 Terme d'attache aux données

Concernant le terme d'attache aux données, un modèle markovien gaussien est choisi. Les pixels de la texture de la chaussée (du fond) suivent une loi de distribution gaussienne (normale), cf. figure avec histogrammes 1.3. Les pixels de la fissure sont supposés suivre une distribution similaire avec une moyenne plus basse. On peut supposer qu'un modèle markovien gaussien est adapté aux images de la chaussée. Le coût local en un site avec ce modèle est défini par :

$$u_2(s) = \sum_{i \in E} \left(\frac{(y_s - \mu_i)^2}{2\sigma_i^2} - \log \sqrt{2\pi\sigma_i^2} \right) \delta(x_s = i) \quad (3.13)$$

où

- $X = x_s$: champ des étiquettes, i : nombre de classes, x_s et $i \in E = 1, 2 / E$ est l'ensemble des étiquettes avec 1 correspondant à la classe « fissure » et 2 correspondant à la classe « fond » ;

- $Y = y_s$: champ des observations, représentant les valeurs des niveaux des gris de l'image de chaussée ;
- $\delta(a)$ est égal à 1 si a est vrai et à 0 sinon ;
- μ_i : moyenne associé à chaque classe i ;
- σ_i : écart-type de chaque classe i ;

Chacune des classes (fissure et fond) est caractérisée par une moyenne et une variance. Il est nécessaire d'estimer ces statistiques pour chaque classe. Le paragraphe suivant nous permet de présenter la méthode d'estimation des paramètres utilisée.

3.1.3 Estimation des paramètres

Pour estimer les paramètres associés au terme d'attache au données gaussien, nous utilisons l'approche standard d'estimation du maximum de vraisemblance via l'algorithme itératif d'Espérance-Maximisation (EM).

Principe – Étant donné un ensemble de données de taille N , $\mathcal{Y} = \{y_1, y_2, \dots, y_N\}$, où chaque élément y_i est tiré d'une distribution de densité de probabilité $P(y/\Theta)$ qui dépend d'un vecteur de paramètres Θ . En supposant que les y_i sont indépendants et identiquement distribués, la densité de probabilité de l'ensemble des données devient :

$$p(\mathcal{Y}|\Theta) = \prod_{i=1}^N p(y_i|\Theta) = \mathcal{L}(\Theta|\mathcal{Y}) \quad (3.14)$$

la fonction $\mathcal{L}(\Theta|\mathcal{Y})$ est appelée la fonction de vraisemblance où les paramètres Θ sont considérés variables et inconnus étant donné que les données \mathcal{Y} sont fixes, le but est de trouver le vecteur Θ qui maximise \mathcal{L} , c'est-à-dire de trouver $\hat{\Theta}$:

$$\hat{\Theta} = \underset{\Theta}{\operatorname{argmax}} \mathcal{L}(\Theta|\mathcal{Y}) \quad (3.15)$$

souvent, le $\log(\mathcal{L}(\Theta|\mathcal{Y}))$ est maximisé car c'est plus facile analytiquement [Bilmes 98]. Dans le cas d'un mélange de densités de probabilité, la densité de probabilité, équation (3.14), est donnée par :

$$p(y|\Theta) = \sum_{i=1}^M \alpha_i p_i(y|\theta_i) \quad (3.16)$$

c'est-à-dire qu'on a M fonctions de densité de probabilité mélangées où α_i est la proportion de chaque densité de probabilité dans le mélange. De plus, $\Theta = (\alpha_1, \dots, \alpha_M, \theta_1, \dots, \theta_M)$, $\sum_{i=1}^M \alpha_i = 1$

et p_i est la densité de probabilité de paramètre θ_i .

Dans notre cas, l'ensemble des données \mathcal{Y} est l'ensemble des niveaux des gris de l'image de chaussée, et c'est un mélange des deux gaussiennes ($M = 2$), où $\theta_i = (\mu_i, \sigma_i)$, $i \in 1, 2$ d'où :

$$p_i(y|\theta_i) = \frac{1}{\sigma_i\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{y-\mu_i}{\sigma_i}\right)\right) \quad (3.17)$$

alors la fonction à maximiser est :

$$\log(\mathcal{L}(\Theta|\mathcal{Y})) = \log \prod_{i=1}^N p(y_i|\Theta) = \sum_{i=1}^N \log \left(\sum_{j=1}^M \alpha_j \frac{1}{\sigma_j\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{y_i-\mu_j}{\sigma_j}\right)\right) \right) \quad (3.18)$$

La maximisation de cette fonction est une tâche difficile car elle contient le log d'une somme. Pour cela \mathcal{Y} est supposé « incomplet » (données observées), et un ensemble des données $\mathcal{Z} = \{z_1, \dots, z_i\}_{i=1}^M$ non observées est supposé. Les valeurs de \mathcal{Z} indique à quelle composante de mélange chaque élément y_i appartient ($z_i \in 1, \dots, M$). La vraisemblance (équation (3.18)) devient :

$$\log(\mathcal{L}(\Theta|\mathcal{Y}, \mathcal{Z})) = \log(p(\mathcal{Y}, \mathcal{Z}|\Theta)) = \sum_{i=1}^N \log(\alpha_{z_i} p_{z_i}(y_i|\theta_{z_i})) \quad (3.19)$$

Pour maximiser cette fonction, l'algorithme EM (Espérance-Maximisation) est généralement utilisé. Par définition, l'algorithme EM est une méthode itérative qui alterne entre deux étapes, l'étape d'Espérance (E) et l'étape de Maximisation (M).

- Espérance (E) : Calcul de l'espérance de la vraisemblance en utilisant l'estimation courante des moyennes et des variances ;
- Maximization (M) : Calcul des paramètres maximisant la vraisemblance espérée trouvée à l'étape E.

Pour plus de détails sur l'EM, plusieurs références existent dans la littérature parmi lesquelles [Dempster 77, Hartley 58].

Les étapes de la méthode d'estimation sont présentées dans l'algorithme décrit dans la figure (3.4).

Initialisation

- Initialisation aléatoire des moyennes et variances des classes (fissure, fond), et des proportions de chaque classe

Étapes

- Estimation de la densité de probabilité des données inobservables :

$$p(z_i = j|y_i, \theta) = \frac{\alpha_j p_j(y_i|\theta_j)}{\sum_{k=1}^M \alpha_k p_j(y_i|\theta_k)} \quad (3.20)$$

- Mise à jour des moyennes et variances et proportions des classes en utilisant les densités de probabilité de l'étape précédente :

$$\hat{\mu}_j = \frac{\sum_{i=1}^N y_i p(z_i = j|y_i, \theta)}{N \alpha_j} \quad (3.21)$$

$$\hat{\sigma}_j = \frac{\sum_{i=1}^N (y_i - \hat{\mu}_j)^2 p(z_i = j|y_i, \theta)}{N \alpha_j} \quad (3.22)$$

$$\hat{\alpha}_i = \frac{p(Z_i = j|y_i, \theta)}{N} \quad (3.23)$$

Condition d'arrêt

- Taux de changement est plus petit q'un seuil

FIG. 3.4 – Algorithme itératif EM (Espérance-Maximisation) pour l'estimation des paramètres du chien-modèle.

3.1.4 Méthode d'optimisation utilisée

Après avoir obtenu les variables d'entrée de l'algorithme, il nous reste à décrire l'algorithme d'optimisation utilisé pour obtenir le résultat de segmentation des fissures. En fait, pour la simulation de nos résultats nous avons choisi d'optimiser le critère bayésien MAP.

Critère MAP – Dans le critère MAP, on cherche la configuration qui maximise la probabilité *a posteriori*, cf. section 2.5. Pour obtenir cette configuration, nous avons utilisé la méthode d'optimisation globale associée avec ce critère, l'algorithme de recuit simulé.

Algorithme de Recuit simulé – C'est un algorithme stochastique basé sur une distribution de Gibbs avec un paramètre de température $T > 0$, ainsi, les équations (2.5) et (2.6) deviennent :

$$P(X = x) = \frac{1}{Z(T)} \exp(-U(x)) \quad (3.24)$$

où

$$Z(T) = \sum_x \exp\left(\frac{-U(x)}{T}\right) \quad (3.25)$$

Cet algorithme est itératif, il est dédié à la recherche d'une configuration d'énergie minimale d'un champ de Gibbs (voir chapitre 2, section 2.5). Les étapes de l'algorithme sont décrites dans la figure 3.5.

Initialisation

- Choix d'une température initiale $T^{(0)}$ suffisamment élevée
- Choix d'une configuration initiale quelconque $x^{(0)}$ (Image)

à l'étape n

- À partir de la configuration $x^{(n-1)}$, simuler la configuration $x^{(n)}$ pour la loi de Gibbs d'énergie $\frac{U(x)}{T^{(n)}}$. La simulation peut être faite par un échantillonneur de Gibbs ou l'algorithme de Metropolis (voir annexe B).
- Décroître lentement la température

Condition d'arrêt

- Le taux de changements est faible
- Le nombre d'itérations est atteint

FIG. 3.5 – Algorithme d'estimation d'un champ de Markov – Cet algorithme est stochastique, il converge vers un minimum global si la décroissance de température est suffisamment lente.

Pour décroître la température de manière lente, on utilise une décroissance géométrique [Kirkpatrick 82] : choisir une suite géométrique de températures tendant vers 0, $t_{i+1} = a \cdot t_i$ avec $0 < a < 1$, c'est-à-dire, à chaque itération, décroître la température par un facteur a .

L'inconvénient de cet algorithme est qu'il est coûteux en temps de calcul puisqu'il demande le calcul d'un grand nombre de configurations au fur et à mesure que la température décroît. Mais son avantage est qu'il est capable de converger vers un minimum global et qu'il n'est pas trop dépendant de la configuration initiale. Naturellement, cette méthode est intéressante pour nous, puisque l'on souhaite obtenir un minimum global.

3.2 Algorithme

En regroupant tous les aspects ci-dessus, nous résumons l'algorithme de la manière suivante :

Variables

- Image de chaussée en niveau de gris Initialisation
- Étiquetage aléatoire de l'image de chaussée
- Moyennes et variances des classes (fissure et fond) estimées par l'algorithme EM
- Coûts élémentaires du chien-modèle : e , l , et n
- Nombre d'itérations : n
- Température initiale : $T^{(0)}$
- Taux de diminution de la température : a

Étapes

1. Pour chaque site s Faire
 - Calculer le coût local $u_s = u_1(s) + u_2(s)$
 - Modifier l'étiquette de s
 - Calculer le nouveau potentiel u'_s
 - Si $u'_s < u_s$, Alors changer l'étiquette de s
 - Sinon, Faire calculer $u''_s = \exp(-(u'_s - u_s)/T^{(n)})$
 - Si $u''_s >$ seuil, Faire changer l'étiquette de s
2. Diminution de la température (d'un facteur a)
3. Retour à l'étape 1 tant qu'il reste des itérations

FIG. 3.6 – Algorithme de segmentation des images de chaussées – Il s'agit de l'algorithme d'étiquetage de chaque site de l'image de chaussée en utilisant les aspects précisés dans la section précédente.

Les coûts $u_1(s)$ et $u_2(s)$ sont les coûts locaux définis par le chien-modèle et le modèle d'attache aux données, ils sont calculés selon les équations (3.12) et (3.13). Le terme T correspond à la température de l'algorithme d'optimisation , le recuit simulé. La simulation d'une nouvelle configuration dans le recuit simulé est faite en utilisant l'algorithme de Metropolis, cf. algorithme dans la figure 3.5, et algorithme de Metropolis en annexe B, figure B.2.

i	Rep.	$V_c^{(b)}(i)$	i	Rep.	$V_c^{(b)}(i)$	i	Rep.	$V_c^{(b)}(i)$
1		0	18		n	35		$0.71e$
2		n	19		$0.63e$	36		n
3		$0.35e$	20		n	37		n
4		n	21		n	38		n
5		$0.28e$	22		n	39		n
6		n	23		$0.56l - 0.32e$	40		n
7		n	24		n	41		n
8		n	25		n	42		n
9		$0.71e$	26		$l - e$	43		n
10		n	27		n	44		n
11		$0.47l - 0.23e$	28		$0.47l - 0.23e$	45		n
12		n	29		$0.48e$	46		n
13		$0.5e$	30		n	47		n
14		$0.35e$	31		n	48		n
15		n	32		n	49		n
16		$0.56l - 0.32e$	33		n	50		n
17		n	34		n	51		n

FIG. 3.3 – Configurations binaires et leurs potentiels dans le chien-modèle.

Chapitre 4

Expérimentation

Dans ce chapitre, nous présentons tout d'abord le protocole d'évaluation qu'on utilise pour évaluer le comportement de la méthode de segmentation des fissures à base de chien-modèle par rapport aux méthodes existants au LCPC. Nous présentons nos résultats expérimentaux, et nous comparons nos résultats avec les résultats obtenus par les deux méthodes : méthode à base de morphologie mathématique et méthode par filtrage adapté.

4.1 Protocole d'évaluation

Pour évaluer une méthode de détection des fissures, il est essentiel de suivre un protocole d'évaluation afin de comparer la méthode avec les autres méthodes et pour qualifier son comportement pour les différentes images des chaussées. Pour cela, et pour identifier la position de notre méthode par rapport aux méthodes précédentes, nous avons suivi le protocole d'évaluation développé au sein du LCPC [Chambon 09].

Trois aspects sont pris en compte dans ce protocole :

- Les images à évaluer ;
- Les images de segmentation de référence de l'images à évaluer ;
- Les critères d'évaluation.

4.1.1 Images de test

Pour évaluer une méthode de segmentation de fissures, les tests sont effectués sur des images synthétiques, des images semi-synthétiques et des images réelles, cf. figure 4.1.

De plus, concernant les images réelles nous souhaitons quantifier le comportement de la méthode de détection avec les banques d'images acquises en statique et en dynamique.

Les images acquises en statique sont des images acquises sur route à partir d'un appareil photo

numérique. Elles sont prises de telle sorte qu'il n'y ait pas de problèmes de luminosité, cf. figure 4.2.

Les images acquises en dynamique sont des images prises par le véhicule d'acquisition en circulation normale. L'éclairage est non-constant, cf. 4.3.

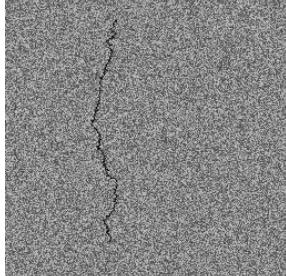
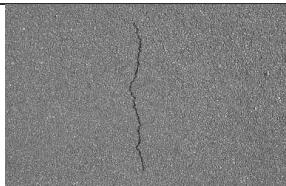
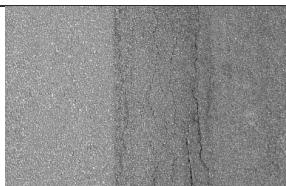
Image	Type	Description
	SYNTHÉTIQUE	FOND ET FISSURE SYNTHÉTIQUES
	SEMI-SYNTÉTIQUE	FOND RÉEL ET FISSURE SYNTHÉTIQUE
	RÉEL	FOND ET FISSURE RÉELS

FIG. 4.1 – Catégories d'images de test utilisées – Nous distinguons les images synthétiques, des images semi-synthétiques et réelles.

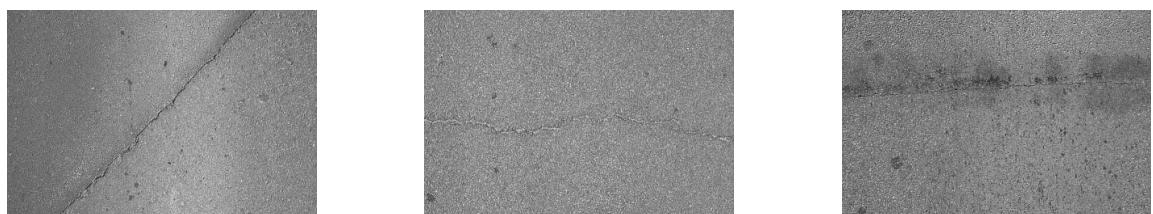


FIG. 4.2 – Images acquises en statique – Il n'y a pas de problèmes d'éclairage dans ces images.



FIG. 4.3 – Images acquises en dynamique – Contrairement aux images acquises en statique, ces images ont un éclairage variable.

4.1.2 Segmentation de référence

Il s'agit d'une banque d'images de référence. Les résultats de la méthode à évaluer sont comparées avec ces images en utilisant les critères d'évaluation expliqués dans la section suivante. Pour les images synthétiques et semi-synthétiques, on connaît la position exacte du défaut. Ses images de segmentation de référence sont appelées images de « vérité terrain ». Concernant les images réelles, on ne connaît pas exactement la position du défaut, les images de segmentation de référence sont obtenues par la fusion de segmentations manuelles réalisées par des experts (4), on dit que ce sont des « pseudo-vérité terrain ». La figure 4.4 montre des images synthétiques, semi-synthétiques et réelles avec leurs images de segmentation de référence.

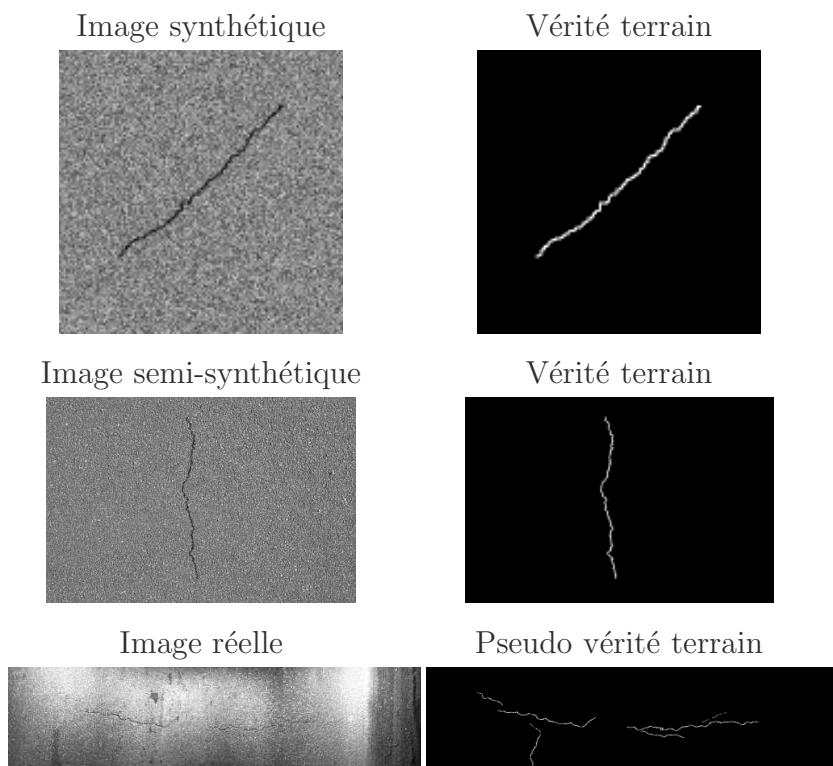


FIG. 4.4 – Images de test avec les segmentations de référence – Nous appelons segmentation de référence, une segmentation manuelle que l'on juge suffisamment fiable pour servir de référence pour une évaluation.

Pour les images réelles, les images de référence sont obtenues de la façon suivante : quatre experts donnent une segmentation de l'image réelles sous les mêmes conditions et à l'aide du même outil [Chambon 09]. Ces segmentations sont fusionnées selon les règles suivants :

- un pixel marqué comme appartenant à une fissure par plus de deux experts est considéré comme un pixel de fissure.

- un pixel voisin d'un pixel de fissure (sélectionné à la première étape) est considéré comme un pixel de fissure.

La figure 4.12 illustre les images réelles avec leurs segmentations de référence (pseudo-vérité terrain).

4.1.3 Critères d'évaluation

Les critères d'évaluation utilisés au sein du LCPC pour comparer un résultat de segmentation d'une méthode spécifique de détection des fissures à la segmentation théorique (vérité terrain ou pseudo-vérité terrain) sont les suivants :

- Pourcentage des bonnes détections ;
- Pourcentage des faux positifs et faux négatifs ;
- Coefficient de similarité.

Ces critères sont expliqués dans la figure 4.5 où nous introduisons les notations.

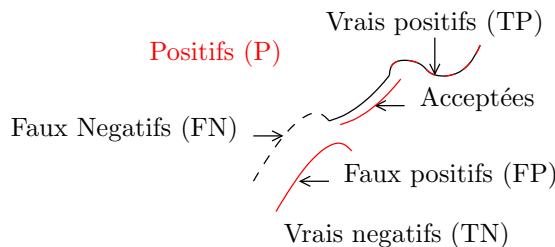


FIG. 4.5 – Schéma présentant les critères d'évaluation – Il s'agit d'une représentation schématique de deux segmentations de la même fissure, une segmentation manuelle (en noir), et une segmentation obtenue en appliquant une méthode de détection automatique (en rouge). Les positifs (P) sont les pixels qui sont détectés comme points appartenant à une fissure par la méthode de détection automatique. Les vrais négatifs (TN) sont les pixels qui ne sont pas détectés comme appartenant à une fissure par la méthode de détection, et qui appartiennent réellement au fond. Les vrais positifs (TP) sont les pixels appartenant à une fissure et qui sont réellement sur une fissure. Les faux négatifs (FN) sont les pixels de fissure qui ne sont pas détectés par la méthode automatique de détection. Les faux positifs (FP) sont les fausses détections obtenues par la méthode de détection.

La table 4.1 illustre les critères d'évaluation d'une méthode de détection automatique des fissures. Parmi ces critères le coefficient de similarité (*DICE*) a été choisi d'être le plus représentatif pour évaluer une méthode de segmentation [Chambon 09]. Il s'agit d'un rapport entre les bonnes détections de la fissure obtenues par la méthode et les détections attendues. Il permet de

synthétiser les résultats obtenus avec les autres critères et de donner l'indication attendue pour l'évaluation.

Sensibilité	$\frac{TP}{TP+FN}$	Proportion des bonnes détections
Spécificité	$\frac{TN}{TN+FP}$	Proportion des pixels non-detectés
Coefficient de similarité (Dice similarity)	$\frac{2TP}{FN+TP+P}$	Rapport entre bonnes détections et points de fissure non-détectés

TAB. 4.1 – Critères d'évaluation d'une segmentation automatique – Nous présentons dans ce tableau tous les critères envisageables. Nous avons choisi d'utiliser le Dice car il représente le mieux ce que nous souhaitons améliorer

4.2 Résultats expérimentaux

Dans cette partie, nous décrivons le comportement de la méthode à base de modélisation markovienne s'appuyant sur le chien-modèle avec des images synthétiques et des images réelles.

Dans un premier temps, on a appliqué la méthode sur des images synthétiques. Tout d'abord, pour les moyennes et variances, nous avons pris les valeurs exactes pour vérifier que la méthode était bien adaptée. On a obtenu les moyennes et les variances en se référant aux images de vérité terrain. Le tableau 4.2 montre les valeurs obtenues pour ces paramètres.

Images	MoyFis	VarFis	MoyFond	VarFond
	26.13	0.22	134.46	1.4
	47.78	0.80	124.45	1.87
	25.67	0.21	134.62	1.41
	35.62	0.37	134.53	2.39
	22.92	0.20	134.77	1.41
	36.58	0.37	134.52	2.40

	22.54	0.22	133.87	1.4
	32.80	0.35	134.36	2.41

TAB. 4.2: Valeurs utilisées pour segmenter les images de synthèse.

Comme attendu, on obtient des résultats très proches de la vérité terrain, cf. Figure 4.6.

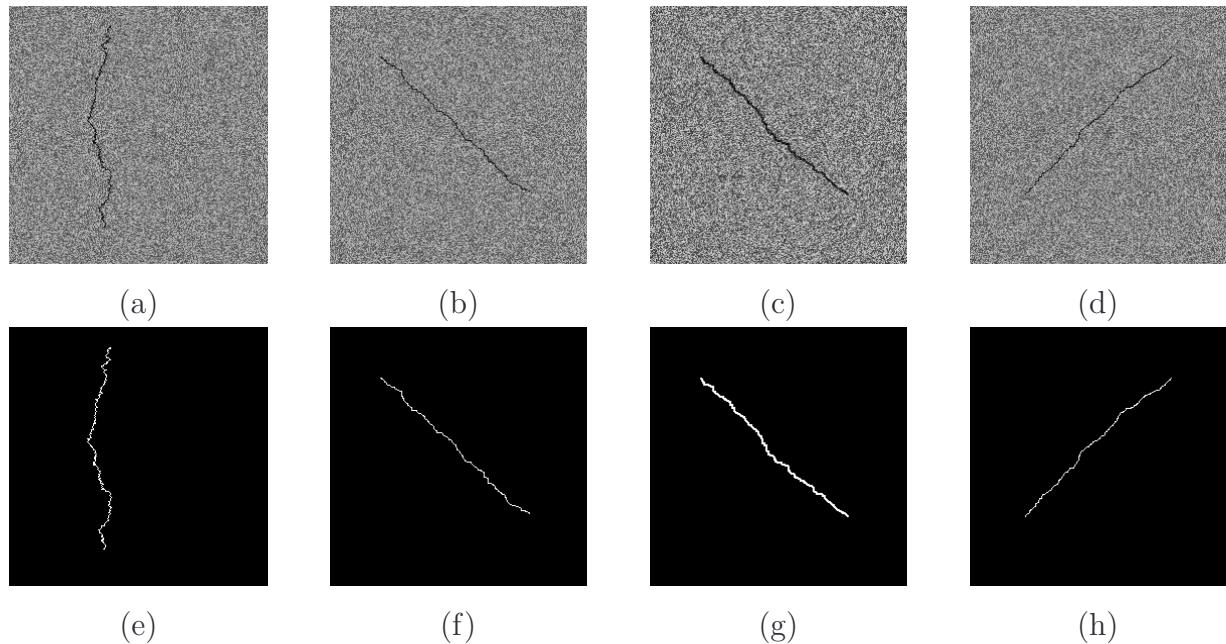


FIG. 4.6 – Images de synthèse et segmentations obtenues en utilisant les moyennes et variances obtenues avec la vérité terrain.

Pour les images réelles, nous appliquons l'algorithme du maximum de vraisemblance via l'EM, cf. l'algorithme dans la figure (3.4). Pour l'initialisation des paramètres d'entrée de cet algorithme (moyennes, variances et proportions de chacune des classes), nous avons utilisé la moyenne et la variance de toute l'image pour initialiser la moyenne et la variance de la classe « fond », et pour la classe « fissure » nous avons initialisé la moyenne par une valeur autour 30 et la variance autour de 5 en se référant aux moyennes et variances obtenues avec la vérité terrain. Nous avons supposé que les proportions de chacune de ces classes sont initialement égales (0.5 pour chacune).

Nous remarquons que le succès de la méthode avec les images de synthèse est dû à

l'indépendance entre les deux classes, c'est-à-dire qu'on trouve peu de pixels de la fissure qui ont le même niveau de gris que des pixels du fond et *vice versa* (par exemple, il n'y a pas de tâches ou autres défauts de la chaussée). Dans l'histogramme, on peut observer deux modes.

4.2.1 Pré-traitements

L'utilisation de pré-traitement est cruciale dans le cas où l'éclairage n'est pas constant. Ainsi, nous effectuons l'étape de pré-traitement principalement pour les images présentant des problèmes d'éclairage. Sans pré-traitement, nous avons obtenu de mauvais résultats pour ces images. En effet dans l'image de résultat, dans les zones sombres de l'image, c'est-à-dire les zones où la variance et la moyenne sont proches de celles de la fissure, nous obtenons de nombreuses fausses détections. Nous illustrons ce fait dans la figure 4.7.

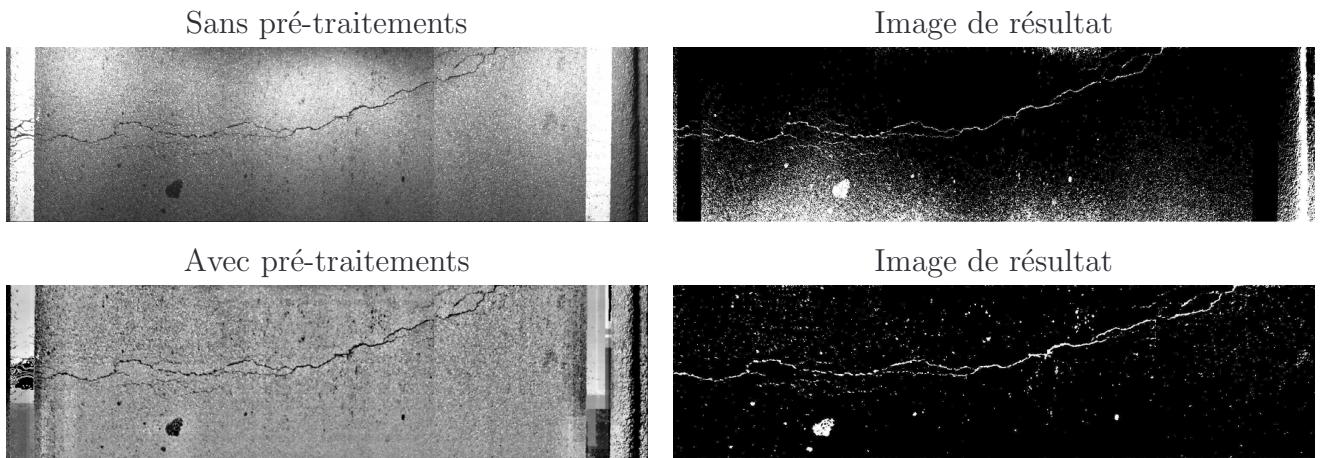


FIG. 4.7 – Comparaison des résultats de segmentation d'une image réelle présentant des problèmes d'éclairage par la méthode par modélisation markovienne basée sur le chien-modèle avec et sans prétraitement.

Les pré-traitements effectués sont :

- *Filtrage médian* – Nous appliquons le filtre médian dont le but est d'atténuer le bruit. Le principe est de substituer au point central d'une fenêtre glissante (voisinage 8-connexe) la valeur médiane des niveaux de gris des pixels de la fenêtre.
- *Filtrage binomial gaussien* – On effectue une convolution de l'image avec le filtre suivant :

$$\begin{pmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{pmatrix}.$$

- *Lissage* – Il s'agit d'appliquer un filtre moyen (à un facteur près) $\begin{pmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{pmatrix}$.
- *Réduction d'éclairage* – Pour ce traitement, on divise l'image en zones d'intérêt, puis on remplace la moyenne des niveaux de gris de chaque zone par une valeur choisie (qui permet de réduire la proportion de pixels affectés par l'éclairage). Pour éviter de voir les démarcations relatives aux limites des zones d'intérêt, le même traitement est réalisé avec des zones de tailles différentes. Au final, l'image restaurée est la moyenne des résultats.
- *Réhaussement du contraste* – On fixe un intervalle « idéal » des variations des niveaux de gris et on effectue un recalage de la dynamique des niveaux de gris.

Ces pré-traitements ont largement contribués à l'amélioration des résultats pour cette nouvelle méthode.

4.2.2 Influence des paramètres

Dans cette section, nous étudions le comportement de la méthode markovienne à base du chien-modèle ainsi que sa sensibilité à ses paramètres (particulièrement les paramètres liés au terme d'attache aux données : variances et moyennes de fond et de fissure). Pour cela, nous affichons le taux de vrais positifs en fonction du taux de faux positifs en faisant varier les paramètres pour une image 136 fois (image 01 de la figure 4.12), c'est-à-dire, nous étudions l'évolution du pourcentage de détection en fonction du pourcentage de fausses alarmes, suivant les variations des différents paramètres. Nous avons fait varier les paramètres de cette façon :

1. Moyenne de la fissure : 10 20 30 40
2. Variance de la fissure : 5 10 15 20
3. Moyenne du fond : 110 120 130 140
4. Variance du fond : 30 40 50 60

Les valeurs étudiées (vrais positifs et faux positifs) sont celles utilisées pour tracer une courbe COR (Caractéristiques Opérationnelles du récepteur) connue dans les applications de diagnostique médical et traitement du signal [Plante 94, Park 04], mais on ne peut pas l'interpréter de la même manière car dans notre cas, nous ne faisons pas varier un paramètre (un seuil de décision) mais quatre paramètres.

D'un point de vue théorique, le détecteur optimal est celui qui donne un pourcentage de fausses alarmes nul pour un pourcentage de détection de 100%. Ceci n'est jamais réalisé en pratique. Alors comme critère de performance, on peut considérer que lorsque la méthode de détection donne un pourcentage de vrais positifs important (plus de 50%) par rapport au

pourcentage de fausses alarmes pour un nombre important de jeu de paramètres, on peut dire que cette méthode est capable de donner des résultats fiables pour un intervalle de jeu de paramètres donné. Une variance forte de la répartition de ces points est un indicateur de la dépendance de la méthode à ses paramètres. La figure 4.8 montre le nuage de points associé aux résultats de test sur une image par la méthode de détection des fissures par le chien modèle.

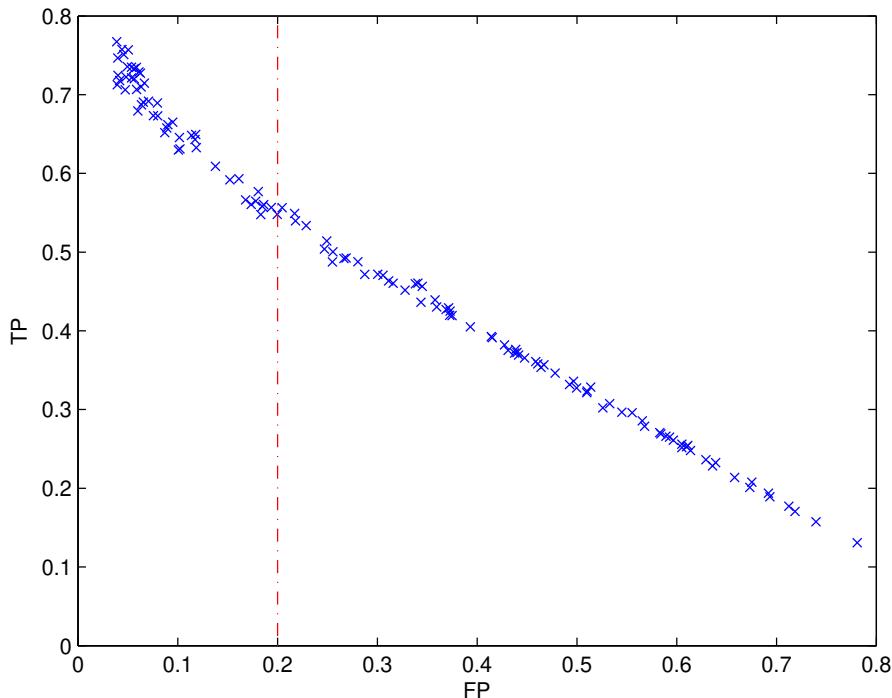


FIG. 4.8 – Taux de faux positifs en fonction du taux des vrais positifs – Cette courbe est un indicateur de la robustesse de la méthode de détection par rapport aux paramètres associés. Chaque point représente un résultat obtenu en utilisant un jeu de paramètres donné. L'intervalle de variation des résultats est important mais le pourcentage de points qui se trouvent dans la partie des résultats acceptables (plus de 50% de bonnes réponses et moins de 20% d'erreur) est important, ce qui montre que le choix des paramètres influence peu la méthode.

Le graphique obtenu indique que le modèle utilisé dépend de ses paramètres mais nous pouvons voir qu'en faisant varier les paramètres, nous avons réussi à obtenir un taux de vrais positifs proche de 1 avec un taux de fausses alarmes faible, dans un nombre de cas important. Si on considère qu'un taux de fausses alarmes plus petit ou égal à 0.2 est satisfaisant, on peut voir que la pourcentage de bonnes détections est plus grand que 0.5 dans cette zone.

Comme le critère Dice est considéré le plus représentatif comme critère d'évaluation, nous affichons également les valeurs de ce critère en fonction des valeurs des pourcentages de vrais positifs pour les différents jeux de paramètres pour montrer les valeurs hauts de Dice obtenus avec cette méthode, cf. figure 4.9. Si on considère qu'un valeur de Dice plus grand ou égal à 0.5 est considéré comme acceptable, alors on peut voir dans la figure 4.9 qu'il existe un grand nombre des points situés au dessus de la ligne Dice = 0.5. Nous obtenons aussi un nombre remarquable de valeurs de Dice plus grande que 0.9.

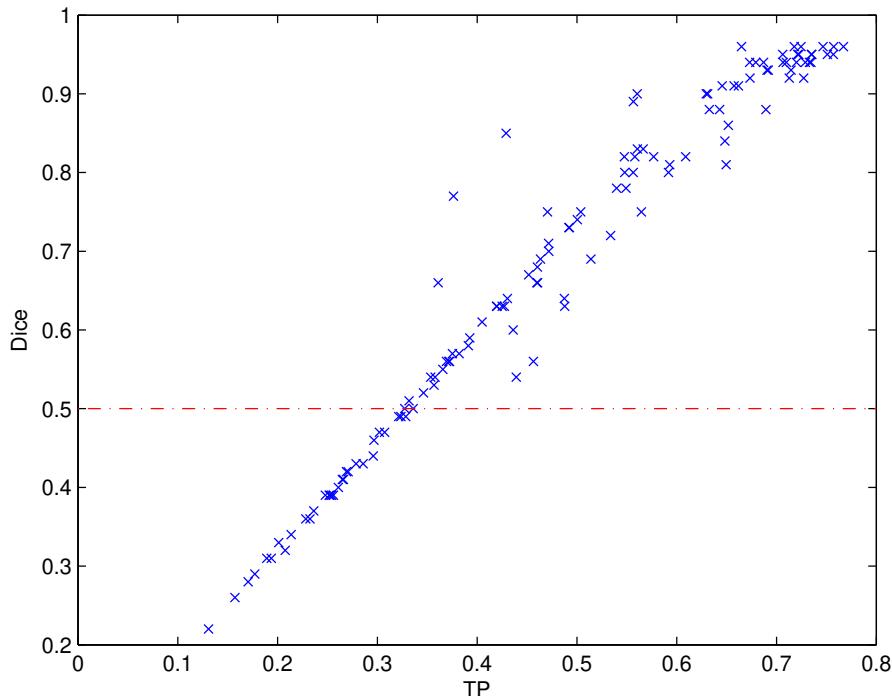


FIG. 4.9 – Variation de la valeur du DICE en fonction des différents jeux de paramètres.

4.2.3 Images de résultats

Dans cette section nous présentons les images de résultats obtenues en appliquant le modèle markovien présenté dans ce mémoire. Ces résultats sont obtenus en initialisant les moyennes et les variances des classes par la méthode d'estimation EM comme indiqué dans le chapitre 3, section 3.1.3. Comme nous avons indiqué dans la section 4.1.1, nous souhaitons quantifier le comportement de la méthode sur des images acquises en statique et en dynamique (rappelons que les images acquises en dynamique ont un problème d'éclairage). La texture de la chaussée varie d'une image à l'autre dans ces deux catégories, alors le comportement de la méthode

varie également avec la texture de la chaussée.

Images acquises en statique

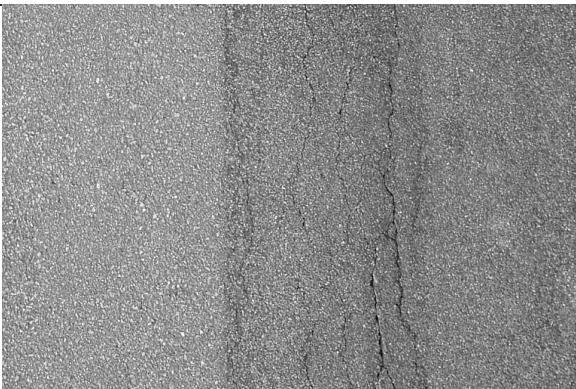
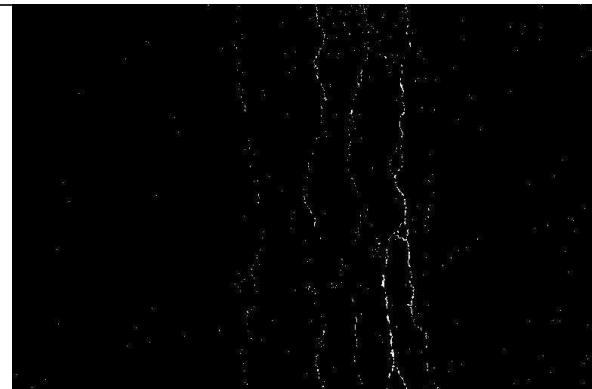
Pour les images 37, 42, 46, 60 et 78, la méthode a réussi à détecter la fissure avec une proportion faible de fausses alarmes.

La fissure des images 01 et 05 est très fine. La texture de la chaussée dans cette image n'est pas très forte (lisse). On peut conclure que la méthode est efficace pour la détection des fissures fines quand la texture n'est pas fortement variable, ou, plus précisément, quand la granularité de la texture n'est pas équivalente à la largeur des fissures observées.

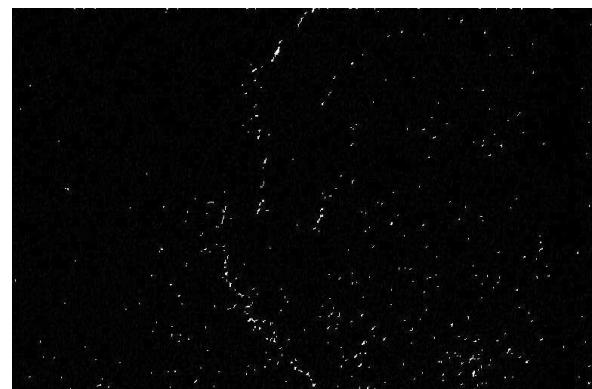
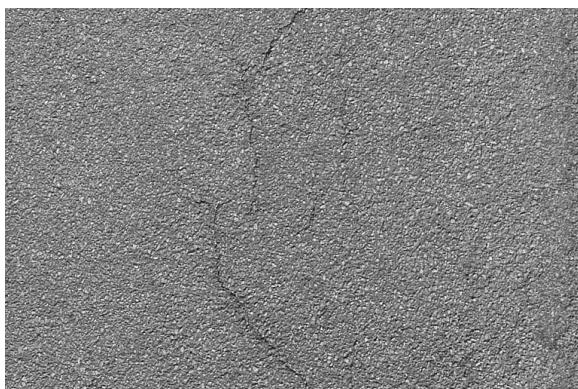
La texture de la chaussée des images 34 et 39 est plus forte (granularité élevée). On peut voir que la méthode donne beaucoup de fausses alarmes, (cf. les nombreux points isolés dans l'image de résultat qui ne correspondent pas à la fissure). Une étude de la texture peut être envisagée pour l'amélioration des résultats pour ce types d'images.

Pour les images avec un problème d'ombre, la méthode n'a pas réussi à palier cette difficulté (images 54 et 66). Un pré-traitement de ces images est nécessaire pour enlever les ombres (mais ce n'est pas l'objet de ce travail).

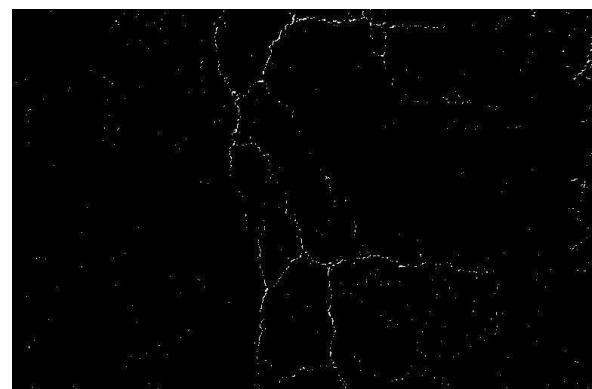
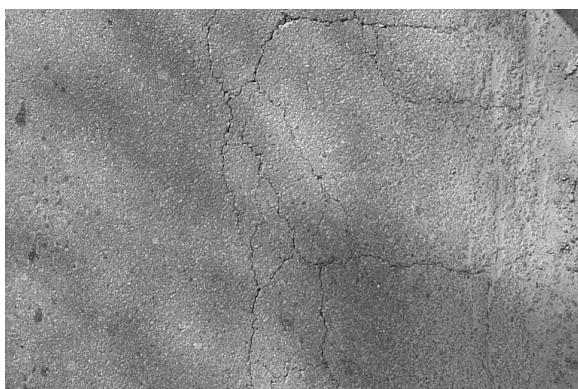
Parfois, nous remarquons l'existence de fissures qui apparaissent moins sombres que la texture de la chaussée, comme c'est le cas des images 54 et 55. Dans ce cas, le niveau de gris des pixels de la fissure sont proches de ceux de la texture. Même si nous arrivons à détecter la fissure (grâce au fait que la méthode prend en compte des aspects géométriques) il y une grande proportion de fausses alarmes qui montre l'échec de la méthode à donner un résultat fiable pour ces images, c'est-à-dire que nous obtenons un Dice inférieur à 0.5.

Nom	Image réelle	Image de résultat
01		

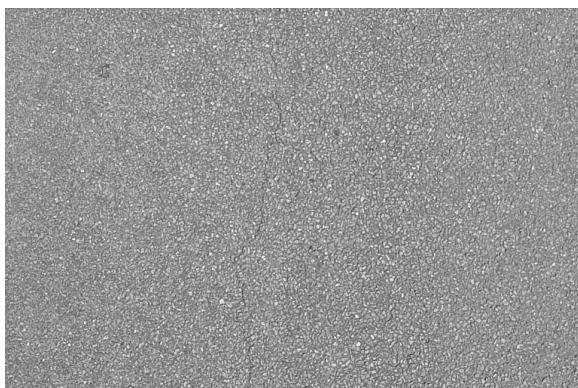
04



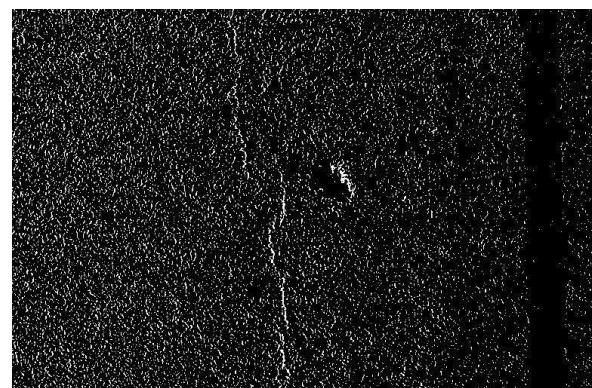
05



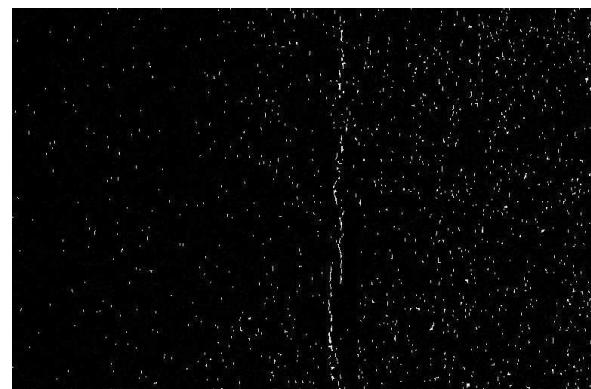
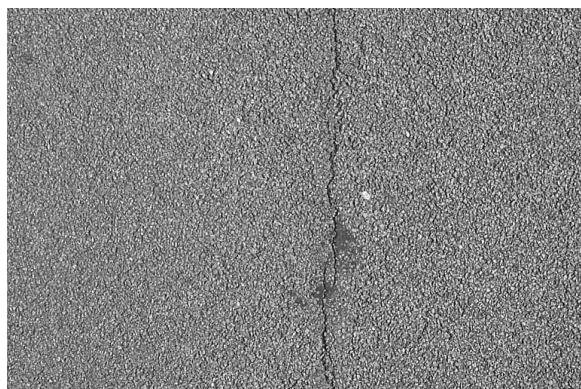
12



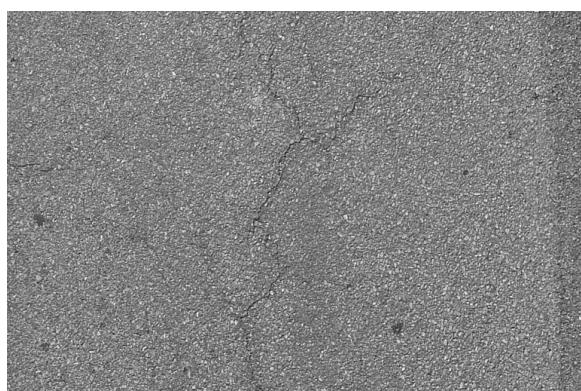
34



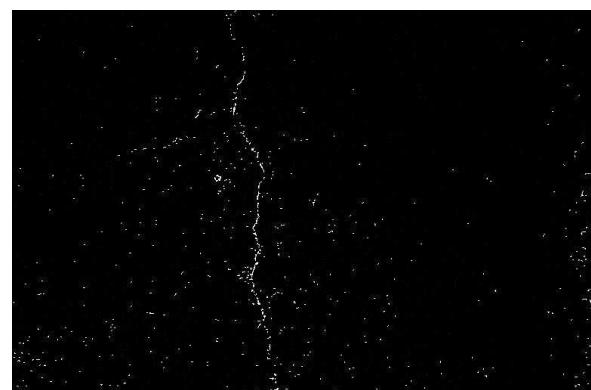
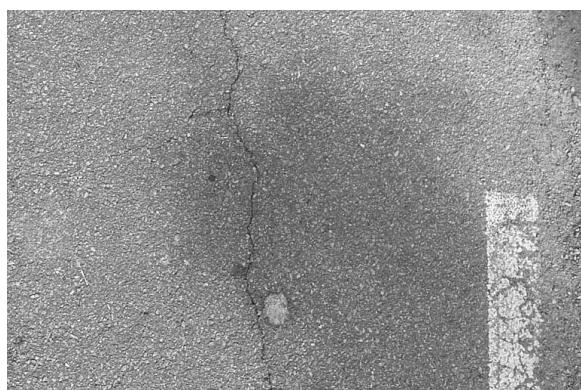
35



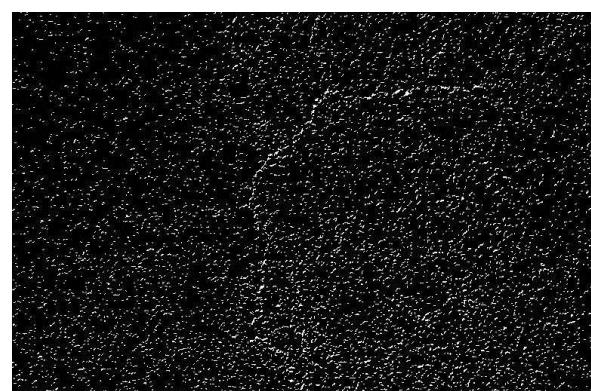
36

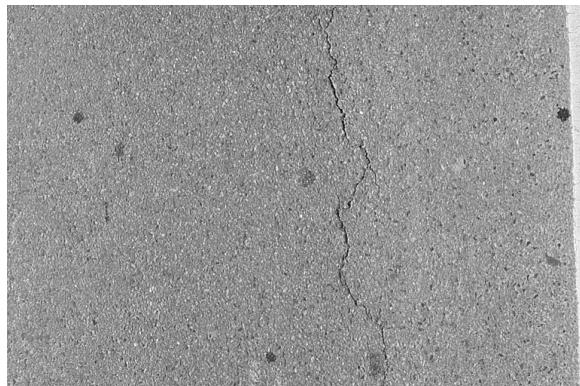


37

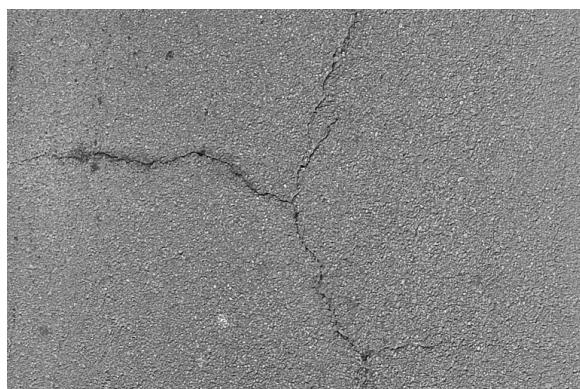
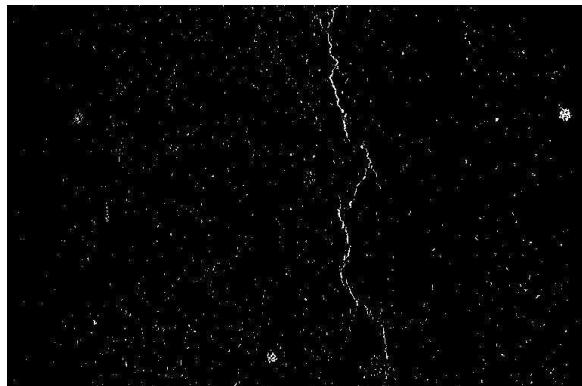


39

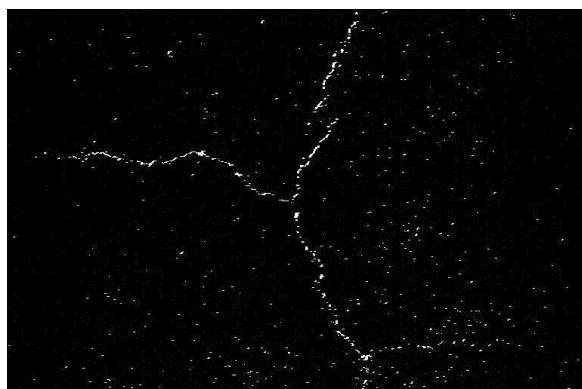




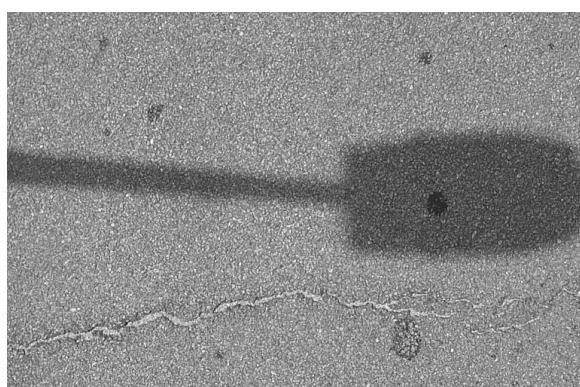
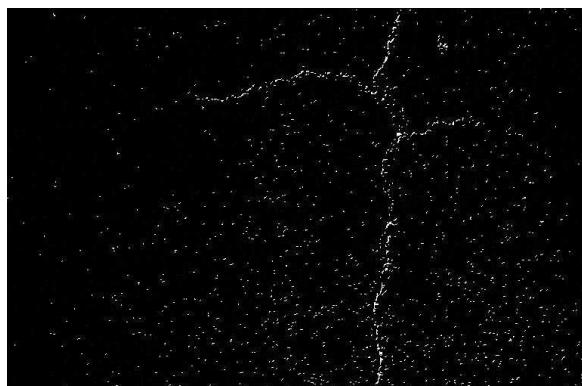
42



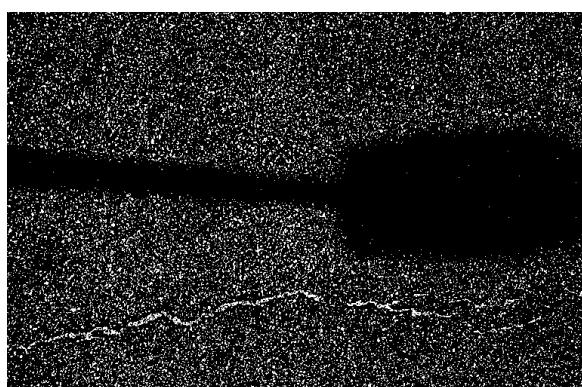
46



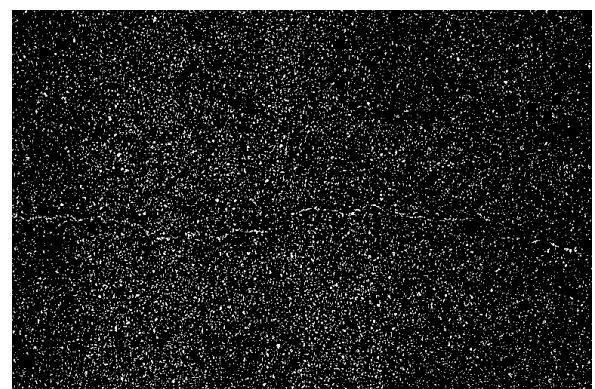
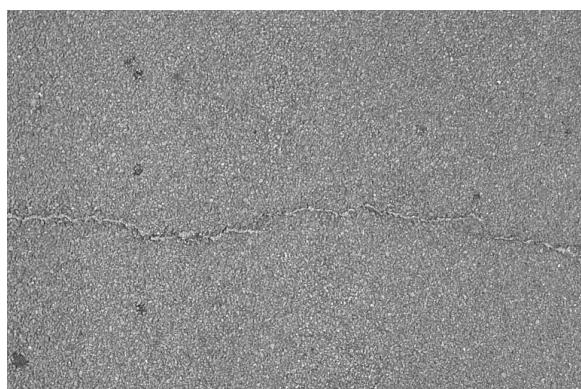
47



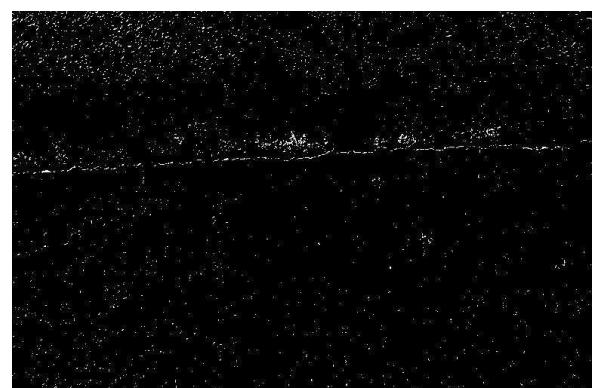
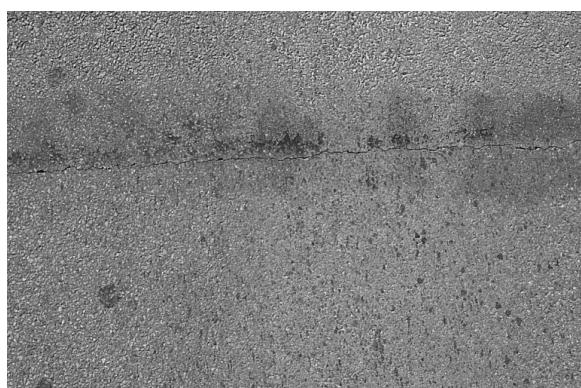
54



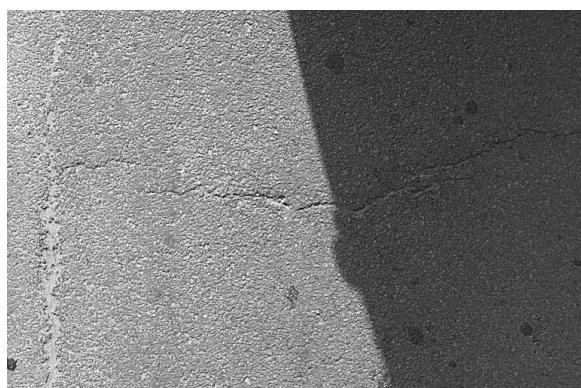
55



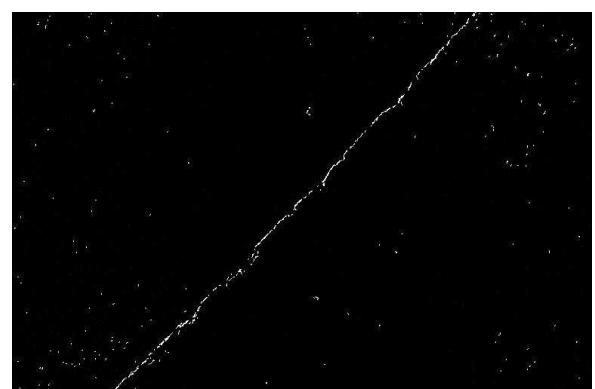
60



66



78



TAB. 4.3: Images des résultats après application de la méthode par modélisation markovienne avec chien-modèle sur des images de chaussée acquises en statique.

Images acquises en dynamique

Les images B22289, B22296, B22302, B22339, B22463 et B22521 sont les images les plus difficiles à traiter. Elles ont une texture très forte et un problème d'éclairage. On peut voir que le pourcentage de fausses détections est le plus élevé parmi toutes les images traitées.

Les images de type *F* sont moins difficiles à traiter, la texture de la chaussée dans ces images est moins forte. La méthode a réussi à détecter la fissure dans ces images avec moins de fausses alarmes que les autres images de cette catégorie.

Un autre problème dans ces images, et également dans toutes les images, est le problème des objets qui ne correspondent pas à la fissure mais qui apparaissent avec des niveaux de gris proches de ceux des fissures. Une solution possible est d'intégrer pour chaque classe plus d'une valeur initiale pour la moyenne et de la variance et, dans ce cas, le calcul du terme d'attache au données dépendra du niveau de gris du pixel concerné. Par exemple, nous pouvons faire une étude locale de l'image (par blocs) et calculer des moyennes et des variances pour chaque bloc et conserver la moyenne et la variance les plus éloignées de celles estimées sur toute l'image. Pour les endroits où on est sur une tâche d'huile, comme dans les images *F23* et *F26* (cf. figure 4.10), on peut souhaiter obtenir de meilleurs résultats.

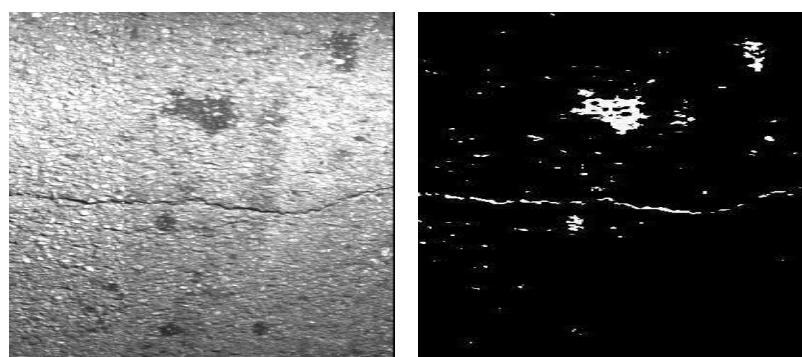
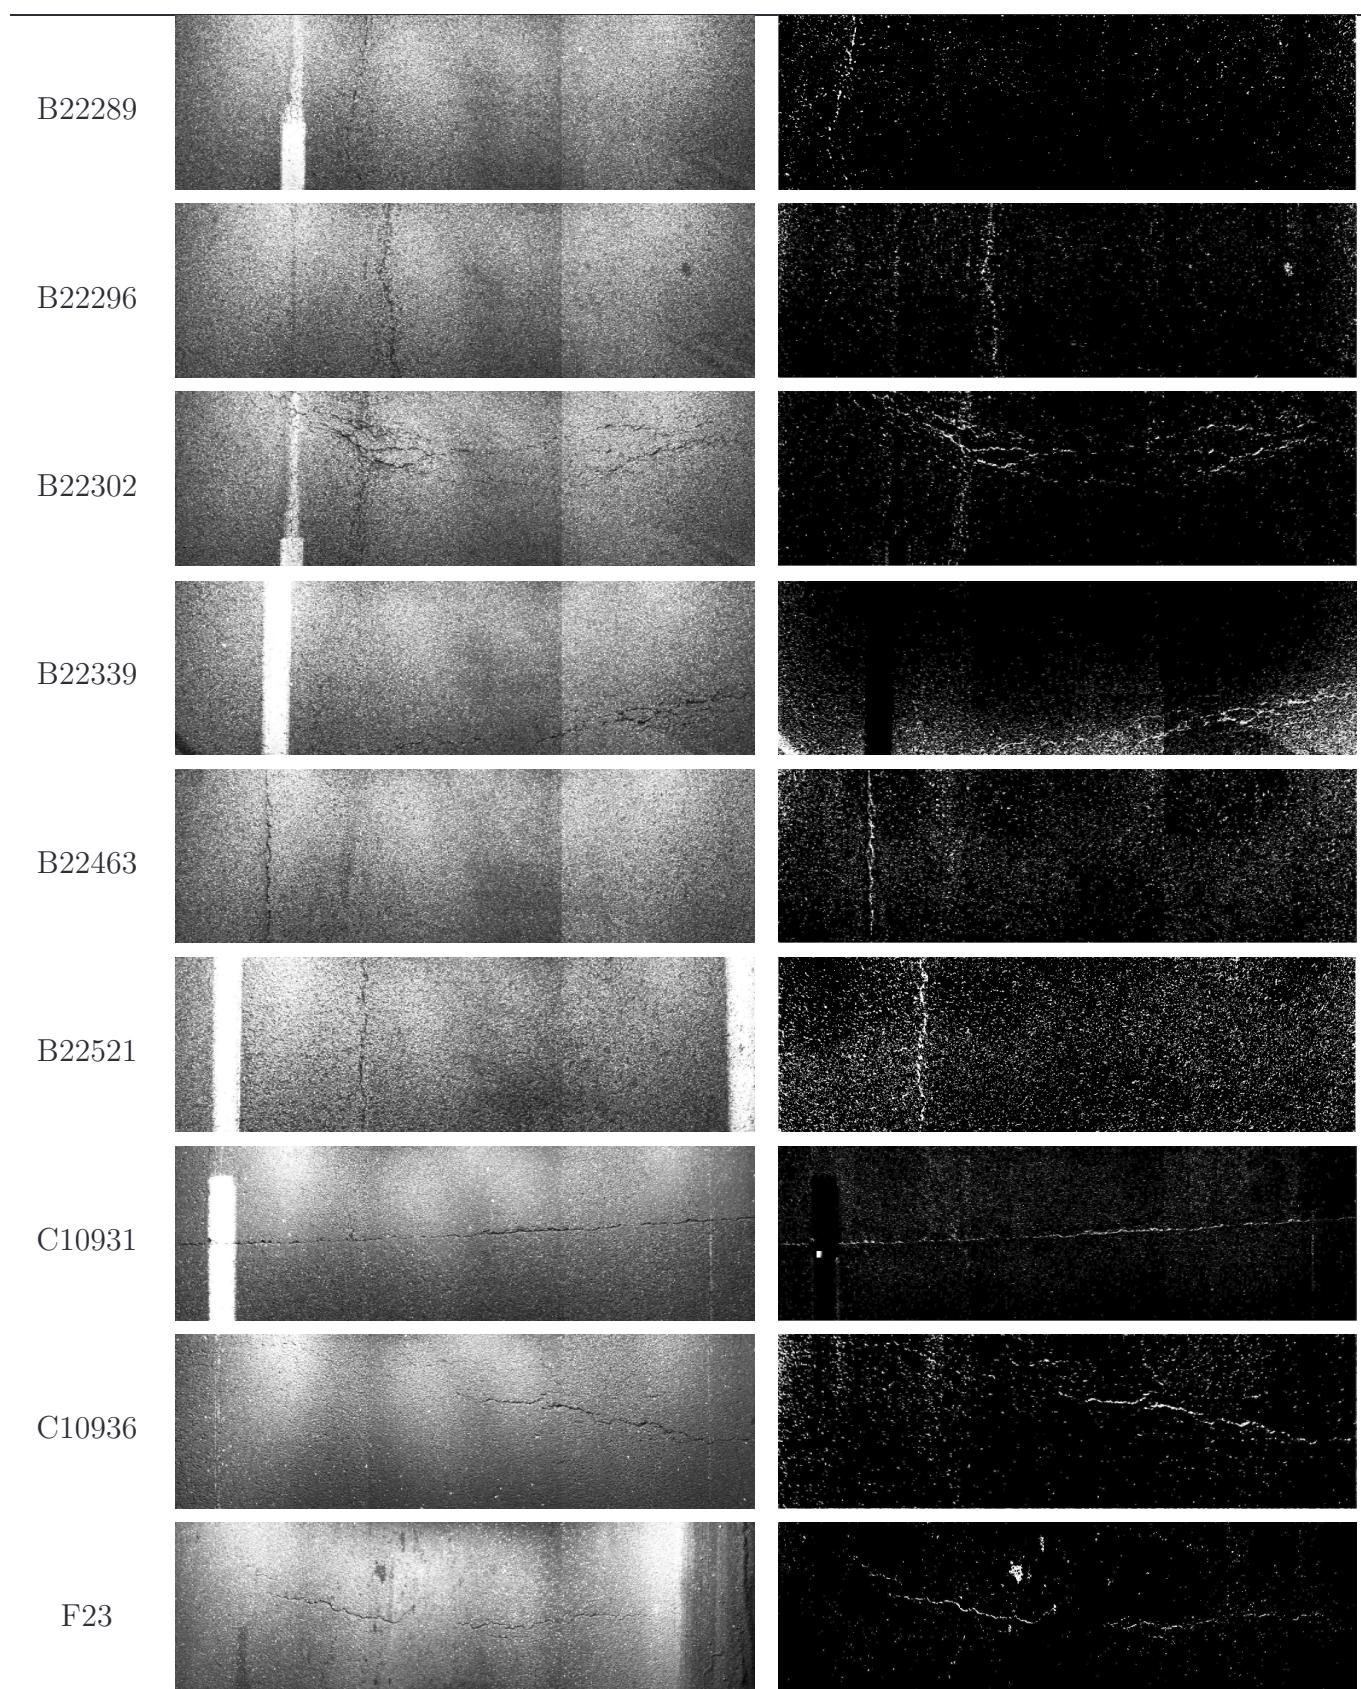
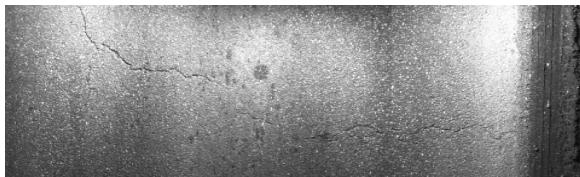


FIG. 4.10 – Détails d'un résultat sur une image réelle – Nous illustrons un cas où le résultat contient une fausse détection correspondant à une tâche d'huile.

Nom	Image réelle	Image de résultat
-----	--------------	-------------------



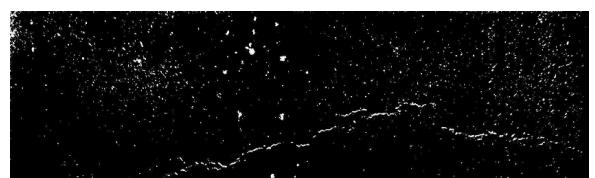
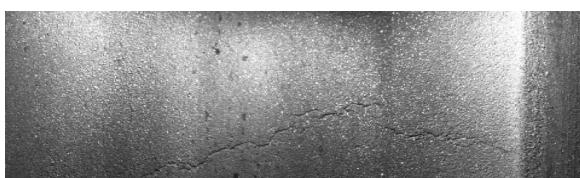
F26



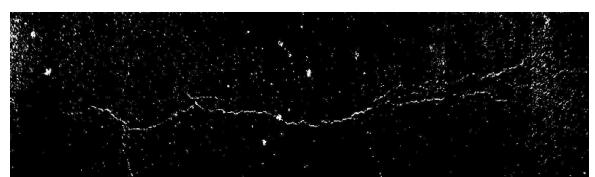
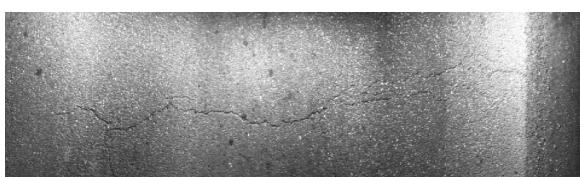
F30



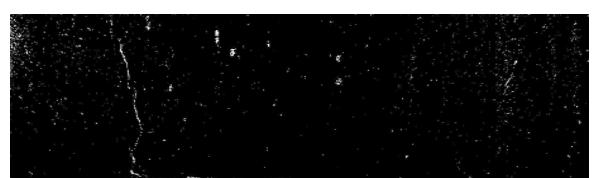
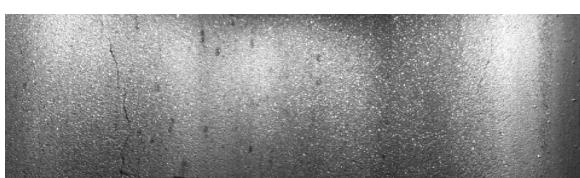
F31



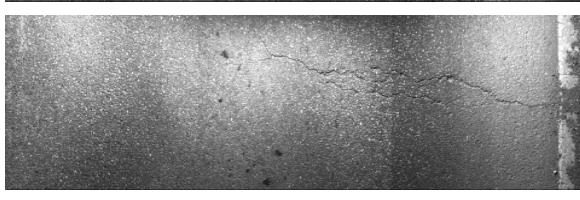
F35



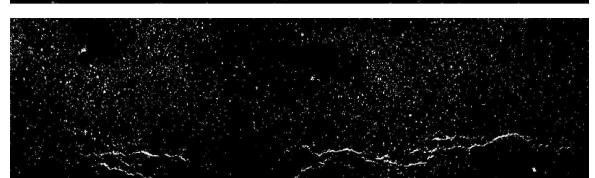
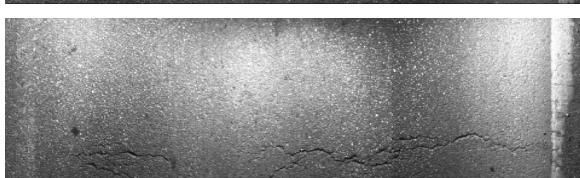
F40



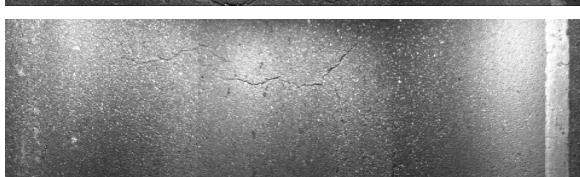
F74



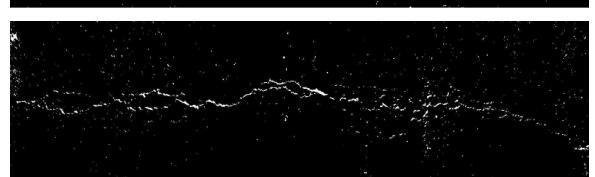
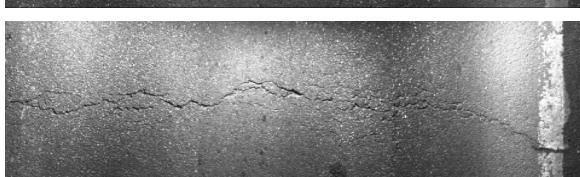
F79

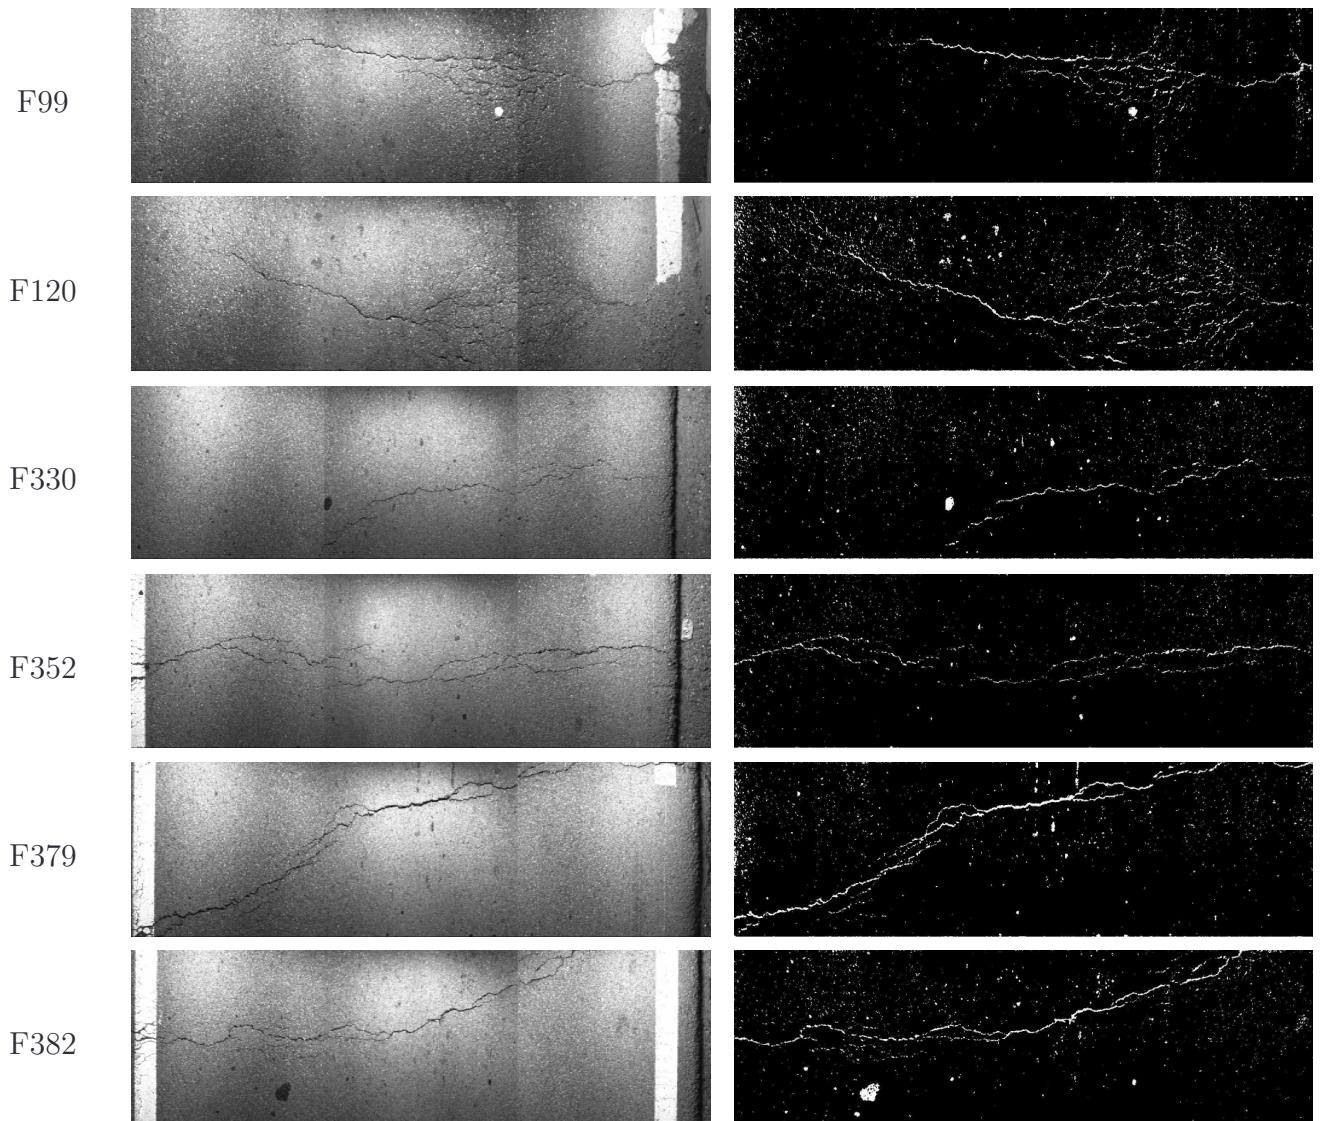


F84



F88





TAB. 4.4: Images des résultats obtenus après application de la méthode par modélisation markovienne avec le chien-modèle sur des images de chaussées acquises en dynamique.

On peut constater que la méthode a réussi à localiser la fissure dans toutes les images acquises en statique et également en dynamique : par localisation, nous voulons dire qu'en regardant l'image de résultat nous pouvons différencier la fissure du fond et des fausses alarmes. Nous souhaitons des images de résultat avec des proportions de fausses alarmes le plus faible possible : c'est le cas pour les images acquises en statique et ayant une texture à peu près lisse, par exemple l'image 78. À présent, il est nécessaire d'adapter la méthode pour qu'elle fonctionne avec d'autres types de texture. Pour les images avec un problème d'éclairage, la localisation de

la fissure est possible mais on a un pourcentage de fausse détections important, ce qui donne une valeur faible pour le Dice.

4.2.4 Influence de la méthode d'estimation

Il est évident que la méthode d'estimation a une influence sur les résultats si on compare la valeur du Dice obtenue avec les paramètres initiaux estimés par la méthode de maximisation de vraisemblance via EM et les valeurs du Dice obtenues avec d'autres jeux de paramètres comme montré dans la section 4.2.2. Pour cela, il est impératif de souligner les inconvénients de la méthode d'estimation utilisée dans cette mémoire.

Le problème avec cette méthode d'estimation est dans le fait qu'on suppose que les deux classes (fissure et fond) sont indépendantes et que la répartition des pixels dans ces deux classe est gaussienne, ce qui n'est pas vrai dans le cas de la classe fissure où on ne connaît pas la loi suivie par cette classe. De plus, il est souvent impossible de distinguer deux modes dans l'histogramme car la proportion de pixels appartenant à une fissure est très faible. Pour palier ce problème, nous pouvons utiliser une méthode d'estimation qui est plus adéquate pour estimer les paramètres dans le cas où on ne peut pas détecter deux modes [Descombes 97b].

Nous avons fixé les paramètres associés au modèle *a priori* (coûts e , l et n) car, d'après nos expérimentations, nous avons pensé que les paramètres associés au terme d'attache aux données ont une plus grande influence sur le résultat que ces paramètres. Une estimation de ces paramètres peut éventuellement améliorer les résultats et rendre la méthode entièrement automatique au niveau du modèle markovien.

4.2.5 Comparaison aux méthodes par morphologie mathématique et par filtrage adapté (méthodes proposées au LCPC)

Pour effectuer cette comparaison, nous analysons les fluctuations des valeurs pour le critère le plus significatif : le coefficient de similarité pour chacune des images et pour chaque méthode (voir section 1.3.3 pour plus de détails sur ces méthodes). En plus, nous exposons les valeurs de tous les critères définis dans le paragraphe 4.1.3, cf. tableau 4.5, afin d'avoir une évaluation et une comparaison plus détaillées. Dans ce tableau, nous observons que pour quelques images, nous avons réussi à améliorer les résultats par rapport aux autres méthodes. Nous marquons en rouge les valeurs de Dice et de TP (vrais positifs) que nous avons obtenus qui sont supérieures à celles obtenues par une des méthodes étudiées au LCPC.

En regardant les valeurs de ce tableau, on ne peut pas conclure sur la meilleure méthode. Il

y a des cas où la méthode a amélioré le résultat par rapport aux deux méthodes LCPC, par exemple 55 et 78. Dans d'autres cas, la méthode proposée est meilleure que la méthode par morphologie mathématique : 37 et F88. On rencontre des cas où elle est mieux que la méthode par filtrage adapté : 36 et F23.

Nous remarquons que le nombre de cas où le valeur de TP (vrais positifs) est améliorée par rapport aux deux méthodes est important, cela veut dire que la localisation de la fissure par la nouvelle méthode est améliorée par rapport aux autres. La faiblesse de la méthode est de fournir trop de fausses alarmes, ce qui ne lui permet pas d'être toujours la meilleure.

Nous illustrons dans la figure 4.11 une image avec les résultats obtenus par chacune des méthodes : morphologie mathématique, filtrage adapté et chien-modèle. Nous remarquons que la localisation de la fissure est améliorée par la méthode avec le chien-modèle par rapport au résultat obtenu par morphologie mathématique. En revanche, nous obtenons plus de fausses alarmes, comparé à la méthode par filtrage adapté. Toutefois, notre résultat est plus complet (c'est-à-dire que nous obtenons la segmentation de la fissure dans son ensemble) que celui obtenu par filtrage adapté.

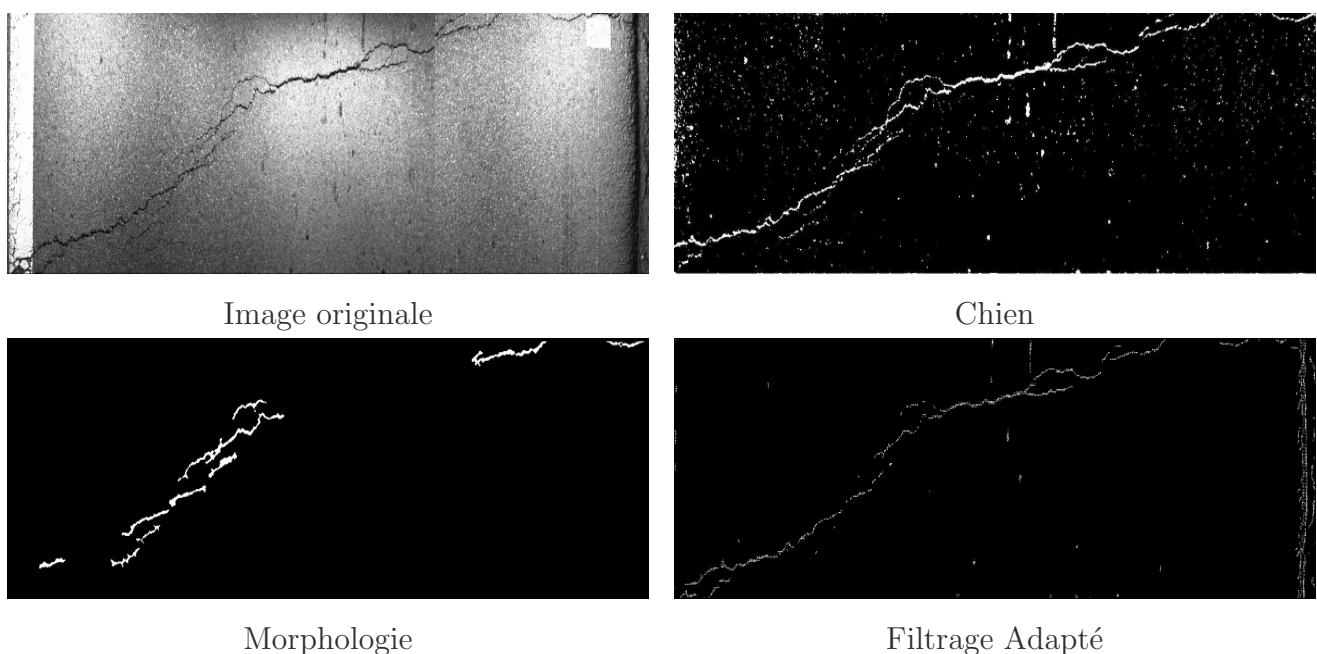
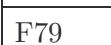


FIG. 4.11 – Comparaison des résultats entre le chien-modèle et les résultats obtenus par filtrage adapté et par morphologie mathématique – La fissure détectée par la méthode avec le chien-modèle est plus localisé (une détection complet de la fissure). Par rapport à la méthode par filtrage adapté, les pixels de la fissure sont plus connectés. En plus une détection des parties fines et petites de la fissure est accomplie. Par rapport à la méthode par morphologie mathématique elle est évident que la fissure est plus localisé par la méthode avec chien-modèle.

Images	TP	Acc	Mau	FN	FP	D	Images	TP	Acc	Mau	FN	FP	D
34 	14.51	26.58	0.93	57.97	14.35	0.56	36 	10.94	39.30	1.78	47.98	23.90	0.62
	17.05	2.74	0.34	79.86	78.48	0.21		0	0	0	100	0	0
	1.90	0.91	0.33	96.86	77.75	0.03		13.73	6.08	1.82	78.37	94.48	0.22
35 	6.06	13.76	0.01	80.17	0	0.33	B96 	7.85	75.10	6.38	10.67	58.32	0.57
	55.04	9.39	0.93	34.65	63.71	0.47		65.16	29.10	1.43	4.30	54.42	0.62
	9.01	3.21	0.94	86.84	92.59	0.13		3.40	1.36	0.95	94.29	82.40	0.06
37 	22.38	47.65	19.13	10.83	84.42	0.27	E41 	5.27	72.64	5.74	16.36	39.55	0.70
	46.56	10.53	1.44	41.47	38.30	0.60		0	0	0	100	0	0
	17.94	7.99	2.70	71.38	91.60	0.29		0.35	0.32	0.35	98.99	96.08	0.01
42 	27.79	58.18	14.03	0	47.94	0.68	F23 	5.70	25.35	1.64	67.31	29.86	0.45
	76.05	5.80	0.95	17.21	5.34	0.88		12.64	2.80	0.22	84.35	66.12	0.21
	14.79	4.36	1.16	79.69	83.01	0.20		18.21	7.74	2.61	71.44	87.89	0.29
46 	24.63	58.82	16.24	0.31	49.39	0.67	F31 	17.72	45.96	2.91	33.41	29.11	0.69
	36.61	6.42	1.31	55.66	31.87	0.54		60.01	11.97	0.61	27.41	18.15	0.77
	37.23	12.06	3.77	46.94	85.54	0.53		11.06	5.68	1.95	81.31	81.58	0.19
47 	17.24	55.07	1.84	25.85	10.65	0.81	F35 	15.65	38.49	0.35	45.51	2.94	0.70
	26.03	12.73	0.35	60.89	20.34	0.52		44.86	13.54	0.52	41.08	17.93	0.69
	12.89	4.95	3.09	79.06	90.41	0.21		14.91	7.41	2.01	75.67	85.01	0.24
54 	8.58	23.13	0.18	68.10	1.16	0.48	F74 	14.46	34.52	0.49	50.54	5.25	0.65
	26.18	7.25	0.12	66.45	10.40	0.49		35.19	8.56	0.37	55.88	19.22	0.57
	8.22	3.94	2.05	85.79	98.14	0.14		22.51	10.10	3.40	63.99	84.95	0.36
55 	0.12	13.93	7.15	78.80	73.05	0.24	F84 	7.67	16.80	0.15	75.39	2.32	0.39
	0	0	0	100	0	0		69.01	21.62	1.26	8.11	21.73	0.85
	22.22	9.72	8.33	59.72	99.39	0.40		22.16	9.02	3.22	65.59	88.63	0.34
60 	3.73	31.28	4.46	60.53	8.28	0.55	F88 	14.45	43.11	3.60	38.83	53.81	0.53
	0	0	0	100	0	0		66.99	13.09	0.78	19.14	39.19	0.69
	4.83	3.84	0.44	90.88	92.50	0.09		33.90	17.23	7.42	41.45	86.89	0.59
78 	22.28	51.93	14	11.79	71.92	0.43	F99 	16.49	38.06	1.56	43.88	18.49	0.66
	27.51	11.52	1.68	59.29	63.13	0.39		61.26	16.36	0.95	21.43	55.81	0.57
	36.39	18.03	5.18	40.40	89.12	0.60		26.54	14.44	6.20	52.82	79.33	0.47
B63 	12.02	30.33	0.26	57.39	1.05	0.60	F82 	17.36	48.32	1.02	33.29	10.01	0.77
	68.73	4.69	0	26.58	0	0.85		58.06	11.96	0.58	29.40	36.90	0.67

La suite sur la page suivante.

Images	TP	Acc	Mau	FN	FP	D	Images	TP	Acc	Mau	FN	FP	D
	1.72	0.74	0.39	97.15	70.84	0.03		19.43	9.99	4.95	65.62	74.70	0.34
C31 	3.90	11.21	1.38	83.50	6.15	0.28		17.04	61.95	2.91	18.10	37.48	0.71
	28.03	7.87	3.22	60.88	29.91	0.50		72.49	26	1.15	0.37	31.37	0.81
	4.16	2.55	0.96	91.88	85.30	0.08		41.69	15.31	3.04	39.96	93.52	0.60
F26 	18.90	40.27	1.59	39.24	16.23	0.70	39 	5.10	39.24	0.74	54.92	15.10	0.59
	34.84	6.80	0.56	57.80	37.57	0.50		0	0	0	100	0	0
	31.17	13.32	3.84	51.67	91.41	0.48		2.59	1.46	0.88	95.06	88.33	0.05
F30 	18.44	49.98	5.07	26.51	56.71	0.54	66 	10.93	33.08	1.09	54.90	26.38	0.56
	33.30	5.10	0.23	61.37	27.91	0.50		21.62	9.72	0.20	68.46	29	0.44
	5.50	3.08	1.35	90.07	84.40	0.10		1.05	0.73	0.47	97.75	79.20	0.02
F40 	5.66	19.13	0.73	74.49	13.05	0.39	B89 	10.36	39.54	0.64	49.46	7.39	0.65
	47.28	16.60	0.34	35.78	25.45	0.69		35.92	11.81	1.07	51.19	52.05	0.48
	13.53	5.68	2.08	78.72	79.38	0.21		0.04	0.02	0.01	99.93	99.18	0.00
F79 	20.81	53.05	2.02	24.12	16.46	0.80	B02 	14.39	65.77	2.49	17.34	23.84	0.79
	49.03	9.67	0.14	41.17	15.97	0.69		49.86	19.43	0.71	30.01	47.26	0.60
	18.63	5.46	1.77	74.13	82.02	0.26		19.09	7.13	3.18	70.60	83.48	0.29
F30 	22.99	53.44	1.27	22.30	8.28	0.84	B39 	8.08	36.81	0.84	54.27	7.40	0.61
	70.37	18.54	1.06	10.02	38.24	0.73		48.21	30.46	2.13	19.20	74.69	0.39
	9.63	4.51	1.71	84.14	80.06	0.16		3.46	2.19	1.52	92.83	72.02	0.07
F79 	10.22	25.94	1.19	62.65	16.13	0.52	B21 	5.40	47	1.25	46.36	12.02	0.67
	0	0	0	100	0	0		0	0	0	100	0	0
	22.94	12.80	7.51	56.75	71.74	0.43		0.11	0.10	0.10	99.69	91.47	0.00
01 	18.99	45.15	1.91	33.95	20.70	0.72	C36 	18.75	55.29	1.42	24.54	12.07	0.81
	55.37	13.92	0.96	29.76	47.01	0.60		56.18	19.56	0.67	23.59	37.46	0.69
	45.03	18.04	2.66	34.27	93.29	0.66		6.17	3.46	1.75	88.62	78.79	0.11
04 	23.36	62.63	0.74	13.27	11.73	0.87	F20 	8.58	23.13	0.18	68.10	1.16	0.48
	75.33	22.34	1.05	1.27	62.89	0.54		26.18	7.25	0.12	66.45	10.40	0.49
	13.36	11.07	4.77	70.80	95.59	0.29		15.60	8.20	3.57	72.64	81.18	0.27
12 	4.02	40.09	2.62	53.27	47.39	0.49	F52 	14.63	37.09	0.88	47.40	11.02	0.66
	23.46	16.09	1.05	59.40	83.03	0.24		55.48	6.46	0.02	38.04	14.47	0.72
	7.07	2.24	0.00	90.69	95.90	0.09		25.74	12.24	5.03	56.99	85.31	0.43

La suite sur la page suivante.

Images	TP	Acc	Mau	FN	FP	D	Images	TP	Acc	Mau	FN	FP	D
--------	----	-----	-----	----	----	---	--------	----	-----	-----	----	----	---

TAB. 4.5: Comparaison des résultats du chien-modèle avec les méthodes LCPC – La première ligne correspond à la méthode par morphologie mathématique, la deuxième ligne à la méthode par filtrage adapté et la dernière ligne à la méthode par chien-modèle.

Conclusion et perspectives

Les difficultés à automatiser la détection des fissures sont multiples. Notamment, parce que c'est un problème de détection d'un objet très fin sur un fond bruité. De plus, le traitement doit pouvoir être appliqué quelle que soit la texture de la chaussée et quelles que soient la largeur et l'orientation des fissures. Dans ce mémoire nous avons appliqué une nouvelle méthode de détection automatique de fissures à base d'une modélisation markovienne par un modèle, le chien-modèle, qui prend en compte la présence de structures fines orientées et qui pénalise le bruit. Les résultats avec les images de synthèse se sont révélés encourageants, car ils dépassent la qualité des résultats obtenus par les méthodes initialement proposées au LCPC, dans le cas des images réelles acquises en statique (sans problème d'éclairage mais avec des textures très variées d'une image à l'autre et non au sein de la même image). Les résultats sont moins bons avec les images présentant des problèmes d'éclairage mais, ce problème est actuellement pris en compte, au LCPC, en tentant d'améliorer le système d'acquisition.

En résumé, les points forts de cette méthode sont :

- Il est possible d'obtenir de bonnes valeurs du critère d'évaluation Dice (meilleurs que les autres méthodes) avec les paramètres optimaux.
- Elle n'a pas besoin d'une bonne initialisation (de l'image de résultat) pour donner de bons résultats (nous initialisons l'image de résultat d'une manière aléatoire).

Pour approfondir notre analyse, grâce aux résultats quantitatifs obtenus par le protocole d'évaluation et de comparaison, nous avons relevé les limites suivantes :

- Cette méthode dépend des paramètres des classes (moyennes et variances de classes), c'est-à-dire qu'elle est dépendante de la méthode d'estimation des paramètres. Alors, si nous nous intéressons à une méthode qui est entièrement bayésienne (tous les paramètres sont estimés), il est impératif de trouver une méthode d'estimation des paramètres qui donne les paramètres optimaux associés à chaque classe de l'image.
- Les résultats obtenus contiennent encore un pourcentage important de fausses détections par rapport à la fissure, ce qui nous donne une valeur de DICE faible dans certains cas même si on a une bonne localisation de la fissure 4.11.

- Dans le cas où l'image a une texture fortement variable comme dans le cas de l'image 41, les résultats obtenus sont insuffisants, alors on en conclue que cette méthode ne permet de traiter la texture que globalement, alors que l'on peut avoir une variation de la texture dans l'image. Ainsi, un modèle local serait plus adapté.

Pour améliorer les performances obtenues par cette méthode, nous pouvons chercher à :

- Prendre en compte la texture de la chaussée dans le traitement. Une étude de la texture peut être effectuée en utilisant la matrice de cooccurrence [Wikipedia 10]. De cette façon, une étude locale selon la variabilité de la texture de l'image sera envisagée.
- Améliorer la méthode d'estimation (qui est le maximum de vraisemblance via l'algorithme EM) des paramètres associés au terme d'attache aux données car dans cette méthode nous supposons que la classe « fissure » suit une distribution gaussienne, ce qui n'est pas la réalité.
- Ajouter une étape d'estimation des paramètres associés au terme *a priori*.

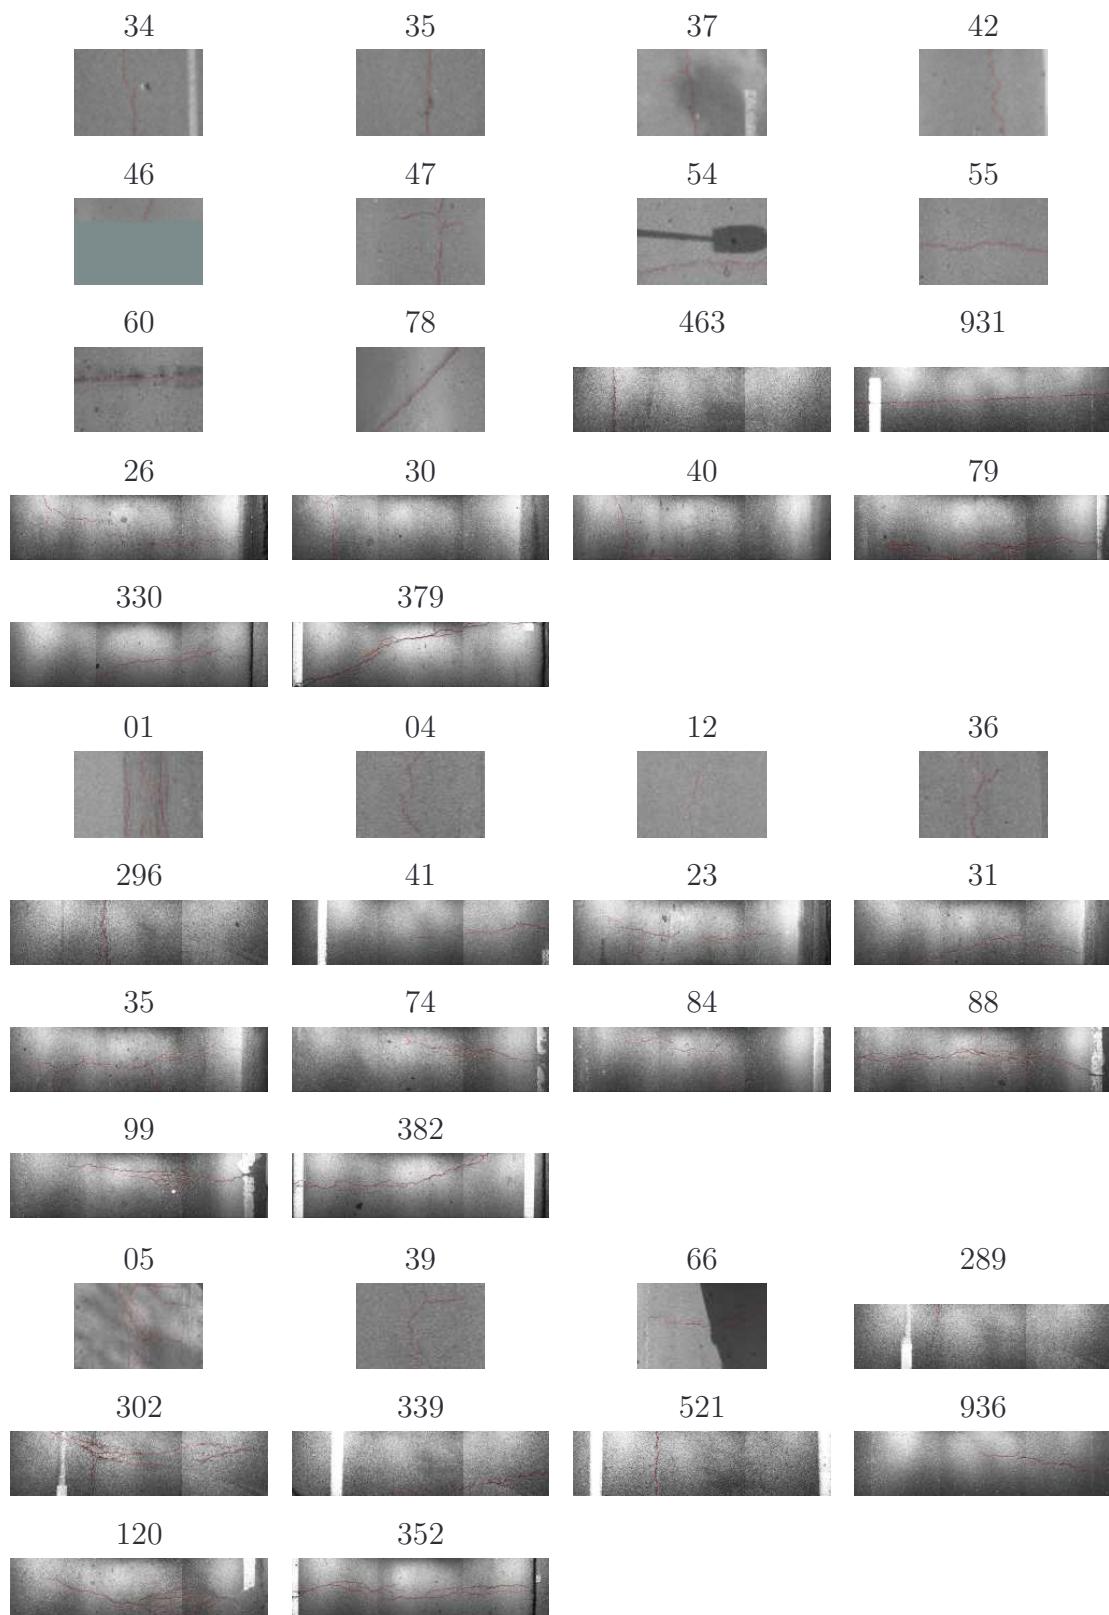


FIG. 4.12 – Segmentations de référence (ou pseudo-vérité terrain) utilisées dans le protocole d'évaluation – Dans chaque image originale, nous illustrons la segmentation finale obtenue en rouge.

DÉTECTION DE FISSURES, RAPPORT DE MASTER RECHERCHE, SEPTEMBRE 2010

Annexe A

Systèmes d'acquisition

Liste de systèmes d'acquisition de données et de détection mentionnés dans cette mémoire, pour plus amples d'information consulter les références associées à chaque système :

HARRIS¹ (*Highways Agency Road Research Information System*) – Ce système est développé par le laboratoire TRL, Transport Research Laboratory. Il s'appuie sur l'utilisation d'un laser combiné à une caméra linéaire. Suite à ce système d'acquisition, des méthodes de détection automatique de fissures ont été mise en œuvre, mais, actuellement, nous avons peu d'information sur les outils utilisés.

ADDA (*Automated Distress Data Acquisition*) – C'est un système américain d'acquisition, très utilisé et très souvent cité dans les travaux américains portant sur le traitement automatique des images acquises.

DESYROUTE² – Le système français DESY ou DESYROUTE [Lorino 07] permet uniquement une aide au relevé pour les releveurs (il ne s'agit pas de détection automatique de fissures). De plus, le relevé est réalisé à 25km/h.

GERPHO – Ce système est développé au sein de Laboratoire Régional de Strasbourg qui permet une auscultation de la route.

SIRANO – Système d'Inspection des Routes et Autoroutes par Analyses Numériques et Optiques, est un système qui a été développé pour être utilisé de nuit, par temps sec, avec un éclairage artificiel. Il permet une détection visuelle uniquement.

ADA (*Automated Distress Analyser*) – Système américain, développé par WayLink³, il permet une détection des fissures de l'ordre du millimètre. La détection des fissures par ce système s'appuie sur une intervention manuelle de l'utilisateur.

¹<http://wwwTRL.co.uk/facilities>

²<http://www.lcpc.fr/fr/presentation/organigramme/>

³<http://www.waylink.com/>

AMAC⁴ – Les systèmes français AMAC® et MACADAM développés par Gilbert Caroff s'appuient sur une acquisition de profils longitudinaux et transversaux. Les traitements de l'image de chaussées réalisés dans ces systèmes sont : suppression des bandes blanches, amélioration du contraste, détection des contours, seuillage par hystérisis, affinement par dilatation, caractérisation suivant la position (dans la bande de roulement ou hors bande de roulement), l'orientation (transversale ou longitudinale) et la distinction entre fissure franche, fissure réparée et faïençage [Soussain 93].

RAV⁵(*Road assesment vehicule*)– Ce système s'appuie sur un filtrage, suivi d'un seuillage et de traitement par outils de la morphologie mathématique et es résultats sont améliorés par filtrage à nouveau. Cet outil intègre un système de classification fondé sur un ensemble de règles exploitant les attributs suivants : surface, périmètre, orientation et connexité.

ARAN (*Automatic Road analyser*) – Ce système est décrit en partie dans cette publication [Rasse 02]. Ce système d'acquisition utilise le logiciel de d'etection Wisecrax® qui s'appuie sur le protocole AASHTO, American Association of State Highway and Transportation Official⁶. Cette d'etection fonctionne en continu et permet la d'etection automatique de fissure jusqu'à 80km. Les images acquises par ce système sont traitées hors ligne, de nuit, par méthode de seuillage. La principale difficulté du système ARAN est qu'il ne peut détecter que des fissures d'au moins 3mm et qu'une même fissure n'est pas détectée de manière continue.

⁴<http://www.vectra.fr/AMAC.pdf>

⁵<http://www.wdm.co.uk>

⁶http://www.roadware.com/software/wisecrax_nt/

Annexe B

Champs de Markov : modèle fondamental et échantillonage

B.1 Modèle d'Ising

Ce modèle est le plus ancien [Ising 25] et le plus simple. Il a été développé lors de l'étude du ferro-magnétisme en physique statistique. L'espace des descripteurs est celui des états binaires $E = -1, 1$ et le voisinage est 4-connexe ou 8-connexe. Les potentiels associés aux cliques d'ordre deux sont des potentiels en tout ou rien:

$$U_{c=(s,t)}(x_s, x_{s'}) = \begin{cases} -\beta s x_s = x_{s'} \\ +\beta s i x_s \neq x_{s'} \end{cases} \quad (\text{B.1})$$

Ce qui s'écrit également $U_{c=(s,t)}(x_s, x_{s'}) = -\beta x_s x_{s'}$ où s et s' sont deux pixels voisins.

Le terme β est la constante de couplage entre sites voisins. Lorsque β est positive on favorise les configurations les plus probables (d'énergies minimales). Cela correspond au terme de régularisation du modèle d'Ising.

Concernant les potentiels d'ordre un du voisinage, ils sont de la forme: $-Bx_s$. Alors l'énergie globale de l'image devient:

$$U(x) = \sum_{c=(s,s') \in C} \beta x_s x_{s'} - \sum_{s \in S} B x_s \quad (\text{B.2})$$

B.2 Échantillonage des champs de Markov

B.2.1 Échantillonneur de Gibbs

Cet algorithme, proposé par [Geman 84], repose sur la construction itérative d'une suite d'images. A la convergence les images construites sont des réalisations tirées selon la loi de Gibbs globale.

La méthode de construction de l'image à l'itération n , partant de l'image à l'itération $n - 1$ se fait par mise à jour successive des sites de l'image. On parle de l'échantillonneur de Gibbs comme d'un algorithme de « relaxation », car il procède par mise à jour successive de sites, et « probabiliste » car elle est fondée sur un tirage aléatoire. Les étapes de la méthode sont décrit dans la figure B.1.

<u>Initialisation</u>
- Choix d'une configuration initiale quelconque x_0 (Image en niveau de gris)
<u>à l'étape n</u>
- Choix d'un site s <u>Pour ce site faire</u>
- Calculer la probabilité conditionnelle locale selon la configuration des voisins V_s de l'image x^{n-1} : $P(X_s = x_s V_s) = \frac{\exp(-U_s(x_s V_s))}{\sum_{x_s} (\exp(-U_s(x_s V_s)))}$
- Mise à jour du site s par tirage aléatoire selon la loi $P(X_s = x_s V_s)$
<u>Condition d'arrêt</u>
- Le taux de changements est faible
- Le nombre d'itérations est atteint

FIG. B.1 – Échantillonneur de Gibbs – Algorithme pour réaliser le tirage d'une configuration (image) en suivant la loi de probabilité de Gibbs caractéristique de ce champ.

Le choix de site s à l'étape n peut être fait par n'importe quelle façon à condition que un très grand nombre de balayages se fait pour chaque site.

B.2.2 Algorithme de Metropolis

Cet algorithme est de type MCMC [Hastings 70]. Il repose sur un principe similaire à l'échantillonneur de Gibbs. La différence est de la façon de mise à jour des sites. On décrit

les étapes de cet algorithme dans la figure B.2.

Initialisation

- Choix d'une configuration initiale quelconque x_0 (Image en niveau de gris)

à l'étape n

- Choix d'un site s Pour ce site faire
- Tirage aléatoire d'un descripteur λ selon une loi uniforme
- Calcul de la variance d'énergie pour $x_s^{(n-1)} \rightarrow \lambda$: $\Delta U = U_s(\lambda|V_s^{(n-1)}) - U_s(x_s^{(n-1)}|V_s^{(n-1)})$
- si $\Delta U < 0$, le changement est accepté : $x_s^{(n)} = \lambda$
- si $\Delta U > 0$, le changement est accepté ou refusé selon la probabilité $p = \exp(-\Delta U)$ et $1 - p$

Condition d'arrêt

- Le taux de changements est faible
- Le nombre d'itérations est atteint

FIG. B.2 – Algorithme de Metropolis. – Algorithme pour réaliser le tirage d'une configuration (image) en suivant la loi de probabilité de Gibbs caractéristique de ce champ.

Bibliographie

- [Acosta 92] J. J. ACOSTA, L. ADOLFO et R. L. MULLEN. *Low-Cost Video Image Processing System for Evaluating Pavement Surface Distress*. *Transportation Research Record: Journal of the Transportation Research Board*, 1348:63–72, 1992.
- [Alekseychuk 07] O. ALEKSEYCHUK et U. ZSCHERPEL. *Recent developments for longitudinal crack detection using a Continuous Density Hidden Markov Model (CDHMM)*. Dans International Symposium on Digital industrial Radiology and Computed Tomography, Lyon, France, juin 2007.
- [A.Pourmorteza 08] A.POURMORTEZA, S. Hamid Reza TOFIGHI, A. ROODAKI, A. YAZDANI et H. SOLTANIAN-ZADEH. *Context-Dependent Segmentation of Retinal Blood Vessels Using Hidden Markov Models*. Dans Advances in Computer Science and Engineering, volume 6 de *Communications in Computer and Information Science*, pages 348–355, novembre 2008.
- [Augereau 01] B. AUGEREAU, B. TREMBLAIS, M. KHOUDIR et V. LEGEAY. *A Differential Approach for Fissures Detection on Road Surface Images*. Dans International Conference on Quality Control by Artificial Vision, Le Creusot, France, mai 2001.
- [Besag 74] J. BESAG. *Spatial interaction and the statistical analysis of lattice systems (with discussions)*. *Journal of the Royal Statistical Society*, 36(2):192–236, 1974.
- [Besag 86] J. BESAG. *On the statistical analysis of dirty pictures*. *Journal of the Royal Statistical Society*, 48(3):259–302, 1986.
- [Bilmes 98] J. BILMES. A gentle tutorial of the em algorithm and its application to parameter estimation for gaussian mixture and hidden markov models. Rapport Technique, International Computer Science institute, 1998.
- [Chambon 08] S. CHAMBON. La détection automatique de défauts dans des images de la chaussée. Rapport technique, Laboratoire Central des Ponts et Chaussées (LCPC), Bouguenais, France, décembre 2008. activité 11N063.
- [Chambon 09] S. CHAMBON. Détection automatique de défauts dans des images de la chaussée : contributions et évaluations. Rapport technique, Laboratoire Central des Ponts et Chaussées (LCPC), Bouguenais, France, octobre 2009. activité 11N063.

- [Cheng 98] H. D. CHENG et M. MIYOJIM. *Novel system for automatic pavement distress detection.* *Journal of Computing in Civil Engineering*, 1764(266):145–152, 1998.
- [Cheng 01] H. D. CHENG, J. L. WANG, Y. G. HU, C. GLAZIER, X. J. SHI et X. W. CHEN. *Novel Approach to Pavement Cracking Detection Based on Neural Network.* *Journal of materials processing technology*, 1764:119–27, 2001. Transportat. Res. Rec.
- [Chou 95] J. CHOU, W. A. O’NEILL et H. CHENG. *Pavement Distress Evaluation Using Fuzzy Logic and Moment Invariants.* *Transportation Research Record: Journal of the Transportation Research Board*, 1505(140):39–46, janvier 1995.
- [Chua 94] K. M. CHUA et L. XU. *Simple procedure for identifying pavement distresses from video images.* *Journal of Transportation Engineering*, 120(3):412–431, 1994.
- [Darwin 95] D. DARWIN, M. N. ABOU-ZEID et K. W. KETCHAM. *Automated crack identification for cement paste.* *Cement and Concrete Research*, 25(3):605–616, avril 1995.
- [Delagnes 95] P. DELAGNES et D. BARBA. *A Markov random field for rectilinear structure extraction in pavement distress image analysis.* Dans International Conference on Image Processing, volume 1, pages 446–449, Washington, États-Unis, octobre 1995.
- [Dempster 77] A. P. DEMPSTER, N. M. LAIRD et D. B. RUBIN. *Maximum likelihood from incomplete data via the EM algorithm.* *Journal of the Royal Statistical Society, B*:1–22, 1977.
- [Descombes 95] X. DESCOMBES, J. F. MANGIN, M. SIGELLE et E. PECHERSKY. *Fine structures preserving Markov model for image processing.* Dans Proceedings of the 9th Scandinavian Conference on Image Analysis, pages 349–356, Uppsala, Sweden, juin 1995.
- [Descombes 96] X. DESCOMBES, M. MOCTEZUMA et J. P. Rudant H. MAÎTRE. *Coastline detection by a Markovian segmentation of SAR images.* *Signal Processing*, 55(12):123–132, 1996.
- [Descombes 97a] R. DESCOMBES, R. MORRIS et J. ZERUBIA. *Quelques améliorations à la segmentation d’images bayésienne. Première partie : modélisation.* *TS. Traitement du signal*, 14(no. 4):373–382, 1997.
- [Descombes 97b] R. DESCOMBES, R. MORRIS et J. ZERUBIA. *Quelques améliorations à la segmentation d’images bayésienne. Seconde partie : classification.* *TS. Traitement du signal*, 14(no. 4):383–393, 1997.
- [Descombes 98] X. DESCOMBES, F. KRUGGEL et D. Yves von CRAMON. *Spatio-Temporal fMRI analysis using Markov random fields.* *IEEE Transactions on Medical Imaging*, 17(6):1028–1038, décembre 1998.

- [Dumoulin 05] J. DUMOULIN, P. SUBIRATS, V. LEGEAY, D. MEIGEN, C. GOURRAUD, J. P.. DELMULLE et M. GARNAUD. *Progressive automation of pavement surface distress detection by imaging techniques*. Dans Proceeding of the Workshop on Instrumentation and Monitoring Methods for Civil Engineering Applications, volume 3, pages 32–45, Nantes, France, décembre 2005.
- [Elbehiery 05] H. ELBEHIERY, A. HEFNAWY et M. ELEWA. *Surface Defects Detection for Ceramic Tiles Using Image Processing and Morphological Techniques*. Proceedings of World Academy of Science, Engineering and Technology (PWASET), 5:158–162, avril 2005.
- [Geman 84] S. GEMAN et D. GEMAN. *Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images*. IEEE Transportation Pattern Analysis, 6:721–741, 1984.
- [Hartley 58] H. HARTLEY. *Maximum likelihood estimation from incomplete data*. Biometrics, 14:17–194, 1958.
- [Hastings 70] W. K. HASTINGS. *Monte Carlo Sampling Methods Using Markov Chains and Their Applications*. Biometrika, 1970.
- [Hellwich 96] O. HELLWICH, H. MAYER et G. WINKLER. *Detection of Lines in Synthetic Aperture Radar (SAR) Scenes*. Chair for Photogrammetry and Remote Sensing, 31(Part B3):313–320, 1996.
- [Hendry 98] A. HENDRY, S. QUEGAN et J. WOOD. *The visibility of linear features in SAR images*. Dans IEEE Int. Geoscience Remote Sensing Symp., pages 1517–1520, Edinburgh, 1998.
- [Ising 25] E. ISING. *Contribution à la théorie du ferromagnétisme*. Journal de Physique, 31:253–258, 1925.
- [Jitprasithsiri 96] S. JITPRASITHSIRI et H. LEE. *Development of a Digital Image Processing Algorithm to Compute a Unified Crack Index for Salt Lake City*. Dans Transportation Research Record, Annual Meeting, Washington, États-Unis, janvier 1996. paper 960889.
- [Katartzis 00] A. KATARTZIS, V. PIZURICA et H. SAHLI. *Application of mathematical morphology and Markov random field theory to the automatic extraction of linear features in airborne*. Mathematical Morphology and its Applications to Image and Signal Processing, 2000.
- [Kirkpatrick 82] S. KIRKPATRICK, C. D. GELATT et M. P. VECCHI. Simulated annealing: theory and applications. Rapport Technique, IBM Research Report RC 9355, 1982.
- [Koutsopoulos 93] H. N. KOUTSOPOULOS, I. EL SANHOURI et A. B. DOWNEY. *Analysis of Segmentation Algorithms for Pavement Distress Images*. Journal of Transportation Engineering, 119(6):868–888, novembre–décembre 1993.

- [LCPC 98] LCPC. Méthode d'essai no. 52. catalogue des dégradations de surface des chaussées. rapport general, Laboratoire Central des Ponts et Chaussées (LCPC), 1998.
- [Lorino 07] T. LORINO. Autopsie d'une chaussée. Rapport Technique, LCPC-Division ESAR, section AGR, 2007.
- [Maredj 02] A. MAREDJ, F. SAADI et D. MEDDOUR. *Segmentation multiéchelle d'images vidéo par la modélisation markovienne*. Dans Journées d'Informatique pour l'entreprise, Algérie, Université de Blida, mars 2002.
- [Meignen 97] D. MEIGNEN, M. BERNADET et H. BRIAND. *One Application of Neural Networks for Detection of Defects Using Video Data Bases: Identification of Road Distresses*. Dans International Workshop on Database and Expert Systems Applications, pages 459–464, Toulouse, France, septembre 1997.
- [Morris 96] R. D. MORRIS, X. DESCOMBES et J. ZERUBIA. *The Ising/Potts model is not well suited to segmentation tasks*. Dans Proceedings of the IEEE Digital Signal Processing Workshop, 1996.
- [Nguyen 07] T. S. NGUYEN, P. VRIGNAT, M. AVILA, S. BEGOT et F. DUCULTY. *Détection de défauts sur la surface de chaussées par système de vision*. Dans Groupe de recherche et d'études du traitement du signal et des images, pages 1097–1100, Troyes, France, septembre 2007.
- [Ouellette 04] R. OUELLETTE, M. BROWNE et K. HIRASAWA. *Genetic algorithm optimization of a convolutional neural network for autonomous crack detection*. Dans Congress on evolutionary computation, pages 7803–8515, Portland OR , Etats Unis, juin 2004. XXX-2371.
- [Park 04] S. H. PARK, J. M. GOO et C. JO. *Reciever operating characteristic (ROC) curve: Practical review for radiologists*. *Korean Journal of Radiology*, 5(1):11–18, mars 2004.
- [Petrov 96] M. PETROV, J. KITTLER et K. Y. SONG. *Automatic surface crack detection on textured materials*. *Journal of materials processing technology*, 56(1–4):158–167, janvier 1996.
- [Plante 94] F. PLANTE. *Paramètres pour l'évaluation acoustique de la nasalité. Etude sur une population d'enfants*. *Journal de physique*, 4(Colloque C5):517–520, 1994.
- [Rababaah 05] H. RABABAHH, J. WOLFER et D. VRAJITORU. *Asphalt Pavement Crack Classification: a Comparison of GA, MLP, and SOM*. Dans Proceeding of the Genetic and Evolutionary Computation Conference (GECCO'05 and SIGEVO 1), pages 1097–1100, Washington, DC, juin 2005.
- [Rasse 02] C. RASSE, V. LEEMANS, M.-F. DESTAIN et J.-C. VERBRUGGE. Bearing capacity of roads, railways and airfiels, Chapitre Application of Image Analysis to the Identification

- and Rating of Road Surface Distress, pages 61–68. ISBN 90 5809 396 4. Correira and Branco, Swets and Zeitlinger, 2002.
- [Shivprakash 05] I. SHIVPRAKASH et S. K. SINHA. *A robust approach for automatic detection and segmentation of cracks of undergroung pipeline images*. *Image and Vision Computing*, 23:921–933, 2005.
- [Sigelle 99] M. SIGELLE et F. TUPIN. Champs de markov en traitement d'images. Rapport Technique, Cours de l'Ecole Nationale Supérieure de Télécommunication de Paris, 1999.
- [Simò 01] A. SIMÒ et E. de VES. *Segmentation of macular fluorescein angiographies. A statistical approach*. *Pattern Recognition Letters*, 34(4):795–809, 2001.
- [Song 95] K. Y. SONG, M. PETROU et J. KITTLER. *Texture crack detection*. *Machine Vision Applications*, 8(1):63–76, janvier 1995.
- [Soussain 93] G. SOUSSAIN. Macadam – documentation générale du système. Rapport Technique, CETE – Méditerranée, janvier 1993.
- [Subirats 06] P. SUBIRATS. *Conception et validation de méthodes de traitement d'images appliquées à la détection de fissures sur les images de surface de chaussées*. Thèse de doctorat, Université de Nantes, Laboratoire Central des Ponts et Chaussées (LCPC), Bouguenais, novembre 2006.
- [Tanaka 98] N. TANAKA et K. UEMATSU. *A Crack Detection Method in Road Surface Images Using Morphology*. Dans Workshop on Machine Vision Applications, pages 154–157, Makuhari, Japon, novembre 1998.
- [Tupin 98] F. TUPIN, H. MAITRE, J. F. MANGIN et J. M. NICOLAS. *Detection of Linear Features in SAR Images: Application to Road Network Extraction*. *IEEE Transactions on Geoscience and Remote Sensing*, 36(2):434–453, mars 1998.
- [Verma 06] J. Bray B. VERMA, X. LI et W. HE. *A Neural Network Based Technique for Automatic Classification of Road Cracks*. International Joint Conference on Neural Networks (IJCNN), pages 907–912, 2006. Transportat. Res. Rec.
- [VETRO 03] A. VETRO, W. YAO et S. HUIFANG. *Rate-distortion modeling for multiscale binary shape coding based on Markov random fields*. *IEEE Transactions on Image Processing*, 12(3):356–364, 2003.
- [Wang 02] K. C. P. WANG et W. GONG. *Automated Pavement Distress Survey: A Review and A New Direction*. Dans Pavement Evaluation Conference, pages 21–25, 2002.
- [Wikipedia 10] WIKIPEDIA. Co-occurrence matrix. apr 2010.
<http://www.manticmoo.com/articles/jeff/programming/latex/bibtex-types.php>.

- [Wu 07] J. WU et A. C. S. CHUNG. *A segmentation models using compound Markov random fields based on boundary model.* *Transactions on Image Processing*, 16(1):241–252, janvier 2007.
- [Yong 08] X. YONG, Z. SHAOGUANG et X. YUYUE. *Markov random field for road extraction applications in remote sensing images.* *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, 37:241–246, 2008.
- [Yu 06] Q. YU et al.. *Filament Preserving Model (FPM) Segmentation Applied to SAR Sea-Ice Imagery.* *IEEE Transactions on Geoscience and Remote Sensing*, 44(12):3687–3694, décembre 2006.
- [Zhou 05] J. ZHOU, P. HUANG et F. P. CHIANG. *Wavelet-based pavement distress classification.* *Transportation Research Record*, 1940:89–98, 2005.